

**PREDIKSI *GLOBAL HORIZONTAL IRRADIANCE* (GHI)
BERBASIS *MULTIVARIATE LSTM* BERDASARKAN POLA MUSIM
DI JAWA TIMUR**

PROPOSAL THESIS

Oleh :

NAMA : RUDI KASianto

NIM : 250605210013



**PROGRAM STUDI MAGISTER INFORMATIKA
FAKULTAS SAINS & TEKNOLOGI
UNIVERSITAS ISLAM NEGERI MAULANA MALIK IBRAHIM
MALANG**

2026

DAFTAR ISI

DAFTAR ISI	1
BAB I PENDAHULUAN	3
1.1 Latar Belakang	3
1.2 Rumusan Masalah	7
1.3 Tujuan Penelitian.....	8
1.4 Manfaat Penelitian	8
1.5 Batasan Penelitian	9
BAB II TINJAUAN PUSTAKA	10
2.1 Landasan Teori	10
2.1.1 Energi Surya.....	10
2.1.2 Radiasi Matahari	10
2.1.3 Global Horizontal Irradiance (GHI).....	11
2.1.4 Variabilitas Musiman Radiasi Matahari	12
2.1.5 Prediksi Radiasi Matahari	12
2.1.6 <i>Deep Learning</i>	13
2.1.7 <i>Long Short-Term Memory (LSTM)</i>	14
2.1.8 Multivariate Long Short-Term Memory (M-LSTM)	16
2.2 Penelitian Terdahulu.....	19
2.3 Research Gap	25
2.4 Hipotesis.....	26
BAB III METODOLOGI PENELITIAN.....	27
3.1 Kerangka Konsep Penelitian	27
3.2 Desain Penelitian.....	29
3.2.1 Data Collection.....	30
3.2.2 Data Preparation.....	32
3.2.3 System Design.....	33
3.2.4 Alur Penelitian	55
3.3 Skenario Eksperimen	57
3.3.1 Konfigurasi dan Skenario Eksperimen.....	57

3.3.2 Implementasi Model.....	59
3.3.3 Lingkungan Pengujian	60
3.4 Plemenary study.....	61
3.4.1 Karakteristik Data	61
3.4.2 Analisis Eksperimen.....	63

BAB I

PENDAHULUAN

1.1 Latar Belakang

Peningkatan kebutuhan energi global dalam beberapa dekade terakhir mendorong berbagai negara untuk melakukan transisi dari energi berbasis bahan bakar fosil menuju energi terbarukan yang lebih ramah lingkungan dan berkelanjutan. Penggunaan energi fosil secara terus-menerus tidak hanya menyebabkan penurunan cadangan energi konvensional, tetapi juga meningkatkan emisi gas rumah kaca yang berdampak terhadap perubahan iklim global. Kondisi tersebut menjadikan pengembangan energi terbarukan sebagai salah satu strategi utama dalam menjaga keberlanjutan energi dan lingkungan di masa depan (*International Energy Agency, 2023*).

Salah satu sumber energi terbarukan yang memiliki potensi besar adalah energi surya. Energi surya berasal dari radiasi elektromagnetik yang dipancarkan oleh matahari dan dapat dimanfaatkan menjadi energi listrik melalui teknologi fotovoltaik. Dibandingkan sumber energi konvensional, energi surya memiliki beberapa keunggulan, seperti ketersediaan yang melimpah, ramah lingkungan, serta biaya operasional yang relatif rendah setelah instalasi sistem dilakukan. Pemanfaatan energi surya juga terus meningkat secara global seiring berkembangnya teknologi pembangkit listrik tenaga surya (PLTS) dan meningkatnya kebutuhan terhadap sistem energi bersih (Duffie & Beckman, 2013).

Dalam perspektif Islam, matahari dipandang sebagai salah satu ciptaan Allah SWT yang memiliki manfaat besar bagi kehidupan manusia. Allah SWT berfirman dalam QS. An-Naba ayat 13:

وَجَعَلْنَا سِرَاجًا وَهَّاجًا

yang artinya “Dan Kami jadikan (matahari) sebagai pelita yang sangat terang (panas)” Ayat tersebut menunjukkan bahwa matahari merupakan sumber cahaya dan panas yang memiliki peran penting bagi kehidupan di bumi.

Perspektif ini sejalan dengan kajian ilmiah modern yang menjelaskan bahwa matahari merupakan sumber utama energi bagi berbagai sistem kehidupan, termasuk sebagai sumber energi terbarukan melalui pemanfaatan radiasi matahari (Azmi et al., 2023; Fahmi, 2023).

Selain itu, Rasulullah ﷺ juga menjelaskan mengenai fenomena panas matahari dalam hadis berikut: *إِذَا اشْتَدَّ الْحَرُّ فَأَبْرِدُوا بِالصَّلَاةِ، فَإِنَّ شِدَّةَ الْحَرِّ مِنْ فَيْحِ جَهَنَّمَ* yang artinya “*Apabila panas sangat menyengat, maka tundalah shalat, karena sesungguhnya panas yang sangat itu berasal dari hembusan neraka Jahannam*” (HR. Bukhari dan Muslim). Kondisi tersebut berkaitan dengan tingginya intensitas radiasi matahari yang diterima permukaan bumi pada waktu tertentu (Fadillah, 2024; Husein & Syahid, 2025). Fenomena ini memperlihatkan bahwa perubahan intensitas panas matahari telah lama menjadi perhatian dalam kehidupan manusia dan memiliki keterkaitan dengan fenomena atmosfer serta kondisi lingkungan. Dengan demikian, kajian mengenai pemanfaatan energi surya tidak hanya memiliki relevansi ilmiah dan teknologi, tetapi juga memiliki nilai reflektif dalam pengembangan ilmu pengetahuan berbasis integrasi sains dan agama.

Dalam sistem energi surya, salah satu parameter utama yang digunakan untuk mengukur potensi energi matahari adalah Global Horizontal Irradiance (GHI). GHI merupakan total radiasi matahari yang diterima oleh permukaan horizontal bumi yang terdiri atas kombinasi radiasi langsung (Direct Normal Irradiance/DNI) dan radiasi difus (Diffuse Horizontal Irradiance/DHI). Nilai GHI menjadi indikator penting dalam berbagai analisis sistem energi surya, khususnya dalam perencanaan, pengoperasian, dan optimasi pembangkit listrik tenaga surya (Domínguez et al., 2024; Yildirim et al., 2023).

Meskipun energi surya memiliki potensi yang besar, pemanfaatannya menghadapi tantangan utama berupa karakteristik radiasi matahari yang bersifat fluktuatif dan dinamis. Intensitas radiasi matahari dapat berubah secara signifikan akibat pengaruh berbagai faktor atmosfer seperti tutupan awan,

aerosol, kelembapan udara, dan perubahan cuaca. Variasi tersebut menyebabkan produksi energi listrik dari sistem tenaga surya menjadi tidak stabil, terutama pada sistem kelistrikan yang membutuhkan keseimbangan suplai dan beban secara terus menerus (D. Huang et al., 2022; Voyant et al., 2017). Oleh karena itu, diperlukan suatu metode yang mampu memprediksi nilai radiasi matahari secara akurat agar sistem energi surya dapat dioperasikan secara lebih optimal.

Prediksi radiasi matahari menjadi salah satu komponen penting dalam pengelolaan sistem energi berbasis tenaga surya. Informasi prediksi radiasi matahari dapat digunakan untuk membantu pengaturan distribusi energi, meningkatkan efisiensi operasional sistem PLTS, serta menjaga stabilitas jaringan listrik. Berbagai pendekatan telah dikembangkan untuk melakukan prediksi radiasi matahari, mulai dari metode statistik konvensional hingga pendekatan berbasis machine learning dan deep learning (Yang et al., 2020).

Dalam beberapa tahun terakhir, metode deep learning semakin banyak digunakan dalam prediksi radiasi matahari karena mampu memodelkan hubungan nonlinier dan pola temporal yang kompleks pada data time series. Salah satu metode deep learning yang banyak digunakan adalah Long Short-Term Memory (LSTM). Metode LSTM merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk mengatasi permasalahan vanishing gradient serta mampu mempertahankan informasi jangka panjang melalui mekanisme memori internal (Hochreiter & Schmidhuber, 1997). Berbagai penelitian menunjukkan bahwa metode LSTM memiliki performa yang lebih baik dibandingkan metode statistik maupun machine learning konvensional dalam prediksi radiasi matahari jangka pendek (Bedoya et al., 2025; Kaysal et al., 2025; Sorkun et al., 2020).

Metode LSTM merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk memproses data time series dengan memanfaatkan mekanisme memori internal. Kemampuan ini memungkinkan LSTM untuk menangkap pola temporal jangka pendek maupun jangka panjang secara efektif. Meskipun demikian, mayoritas penelitian masih berfokus pada

metode univariat yang hanya memanfaatkan satu variabel utama, sehingga belum sepenuhnya mampu merepresentasikan kompleksitas faktor yang mempengaruhi nilai GHI (Hochreiter & Schmidhuber, 1997; J. Huang et al., 2020).

Salah satu pendekatan yang dapat digunakan adalah Multivariate Long Short-Term Memory (M-LSTM). Metode ini memungkinkan model memproses beberapa variabel input secara simultan sehingga mampu mempelajari hubungan temporal dan hubungan antarfitur secara lebih kompleks dibandingkan pendekatan univariat. Penelitian sebelumnya menunjukkan bahwa penggunaan pendekatan multivariat mampu meningkatkan akurasi prediksi radiasi matahari dibandingkan model univariat karena memanfaatkan informasi tambahan dari variabel lain yang relevan (Alharbi & Csala, 2021; Sorkun et al., 2020).

Selain penggunaan variabel multivariat, resolusi temporal data juga menjadi faktor penting dalam prediksi radiasi matahari. Sebagian besar penelitian terdahulu masih menggunakan data resolusi rendah seperti data per jam atau harian sehingga belum mampu merepresentasikan dinamika perubahan radiasi matahari secara detail. Padahal, perubahan radiasi matahari dapat terjadi dalam waktu yang sangat singkat akibat perubahan kondisi atmosfer. Penggunaan data resolusi tinggi, seperti data per menit, dinilai mampu memberikan informasi temporal yang lebih rinci sehingga berpotensi meningkatkan akurasi model prediksi (Delgado et al., 2024; Kaysal et al., 2025).

Indonesia sebagai negara tropis memiliki potensi energi surya yang tinggi sepanjang tahun, namun juga memiliki karakteristik atmosfer yang kompleks akibat pengaruh musim hujan dan musim kemarau. Variabilitas cuaca yang tinggi menyebabkan pola radiasi matahari di wilayah tropis menjadi lebih dinamis dibandingkan wilayah subtropis. Kondisi tersebut menjadikan prediksi radiasi matahari di Indonesia memiliki tingkat kompleksitas yang lebih tinggi

dan memerlukan pendekatan model yang mampu menangkap perubahan temporal secara adaptif.(Suwadana et al., 2025).

Berdasarkan tinjauan penelitian terdahulu, terdapat beberapa research gap yang menjadi dasar dalam penelitian ini. Pertama, penelitian yang secara khusus membandingkan performa model LSTM univariat dan multivariat LSTM masih relatif terbatas. Kedua, sebagian besar penelitian menggunakan data resolusi rendah sehingga belum mampu menangkap dinamika radiasi matahari secara detail. Ketiga, penelitian prediksi GHI berbasis deep learning di wilayah tropis, khususnya Indonesia, masih belum banyak dilakukan. Keempat, analisis pengaruh musim hujan dan musim kemarau terhadap performa model prediksi GHI juga masih jarang dieksplorasi secara mendalam.

Berdasarkan permasalahan dan research gap tersebut, penelitian ini mengusulkan penggunaan metode Multivariate Long Short-Term Memory (M-LSTM) untuk memprediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan menggunakan data radiasi matahari resolusi tinggi di wilayah Malang, Jawa Timur. Metode LSTM digunakan sebagai baseline untuk membandingkan peningkatan performa yang dihasilkan oleh pendekatan multivariat. Selain itu, penelitian ini juga menganalisis pengaruh musim hujan dan musim kemarau terhadap performa model prediksi. Penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan metode prediksi radiasi matahari berbasis deep learning pada wilayah tropis serta mendukung pengembangan sistem energi surya yang lebih optimal.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa metode Long Short-Term Memory (LSTM) dalam memprediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan?

2. Bagaimana performa metode Multivariate Long Short-Term Memory (M-LSTM) dalam memprediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan?
3. Bagaimana perbandingan performa antara metode LSTM dan M-LSTM dalam prediksi GHI?
4. Bagaimana pengaruh penambahan variabel DNI, DHI, Reflektive, Nett Radiation, Azimuth, elevasi, dan fitur waktu terhadap akurasi prediksi GHI?
5. Bagaimana pengaruh musim hujan dan musim kemarau terhadap performa model prediksi GHI?

1.3 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Mengembangkan model Long Short-Term Memory (LSTM) untuk prediksi Global Horizontal Irradiance (GHI) satu jam ke depan.
2. Mengembangkan model Multivariate Long Short-Term Memory (M-LSTM) untuk prediksi Global Horizontal Irradiance (GHI) satu jam ke depan.
3. Menganalisis perbandingan performa antara metode LSTM dan M-LSTM.
4. Menganalisis pengaruh penggunaan variabel multivariat terhadap akurasi prediksi GHI.
5. Menganalisis pengaruh musim hujan dan musim kemarau terhadap performa model prediksi GHI.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat baik secara akademis maupun praktis.

1. Manfaat Akademis

Penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan kajian prediksi radiasi matahari berbasis deep learning, khususnya penggunaan metode *Multivariate Long Short-Term Memory* (M-LSTM) pada data time series resolusi tinggi. Selain itu, penelitian ini juga diharapkan dapat memperkaya

kajian ilmiah terkait pengaruh penggunaan variabel multivariat dan pola musiman terhadap akurasi prediksi Global Horizontal Irradiance (GHI) pada wilayah tropis.

2. Manfaat Praktis

Hasil penelitian ini diharapkan dapat mendukung pengembangan sistem prediksi energi surya yang lebih akurat untuk membantu proses perencanaan dan pengelolaan pembangkit listrik tenaga surya (PLTS). Dengan adanya prediksi GHI yang lebih baik, proses pengambilan keputusan terkait distribusi energi, efisiensi operasional, dan stabilitas sistem kelistrikan dapat dilakukan secara lebih optimal, khususnya pada wilayah tropis seperti Indonesia.

1.5 Batasan Penelitian

Agar penelitian lebih terarah dan fokus, maka batasan penelitian yang digunakan adalah sebagai berikut:

1. Dataset yang digunakan merupakan data radiasi matahari dengan resolusi temporal per menit selama periode 1 Mei 2025 hingga 30 April 2026 di wilayah Malang, Jawa Timur.
2. Target prediksi dalam penelitian ini adalah nilai *Global Horizontal Irradiance* (GHI) satu jam ke depan.
3. Metode yang digunakan dalam penelitian ini adalah *Long Short-Term Memory* (LSTM) dan *Multivariate Long Short-Term Memory* (M-LSTM).
4. Variabel input yang digunakan meliputi GHI, DNI, Diffuse (DHI), reflective Radiation, Net radiation, Azimuth, elevation.
5. Penelitian ini tidak menggunakan variabel meteorologi tambahan seperti suhu udara, kelembapan udara, dan kecepatan angin.
6. Evaluasi performa model dilakukan menggunakan *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan *Coefficient of Determination* (R^2).
7. Analisis dilakukan berdasarkan dua kategori musim, yaitu musim hujan (Oktober 2025 – April 2026) dan musim kemarau. (Mei 2025 – September 2025)

BAB II

TINJAUAN PUSTAKA

2.1 Landasan Teori

2.1.1 Energi Surya

Energi surya merupakan energi yang berasal dari radiasi elektromagnetik yang dipancarkan oleh matahari dan menjadi salah satu sumber energi terbarukan yang paling potensial untuk dikembangkan. Energi ini dapat dimanfaatkan melalui berbagai teknologi konversi energi, salah satunya teknologi fotovoltaik yang mampu mengubah energi radiasi matahari menjadi energi listrik secara langsung melalui efek fotolistrik pada material semikonduktor (Duffie & Beckman, 2013).

Pemanfaatan energi surya terus mengalami peningkatan dalam beberapa dekade terakhir sebagai bagian dari upaya global untuk mengurangi ketergantungan terhadap energi fosil dan menurunkan emisi gas rumah kaca. Laporan International Energy Agency (IEA) menunjukkan bahwa kapasitas instalasi pembangkit listrik tenaga surya mengalami pertumbuhan yang signifikan di berbagai negara karena dinilai lebih ramah lingkungan dan berkelanjutan dibandingkan sumber energi konvensional (International Energy Agency, 2023)

Meskipun memiliki potensi yang besar, sistem energi surya memiliki tantangan utama berupa ketidakstabilan produksi energi akibat fluktuasi intensitas radiasi matahari. Perubahan kondisi atmosfer seperti tutupan awan, aerosol, dan kelembapan udara menyebabkan intensitas radiasi matahari berubah secara dinamis sehingga memengaruhi performa sistem pembangkit listrik tenaga surya (Voyant et al., 2017). Oleh karena itu, diperlukan sistem prediksi radiasi matahari yang akurat untuk mendukung optimasi dan stabilitas sistem energi surya.

2.1.2 Radiasi Matahari

Radiasi matahari merupakan energi elektromagnetik yang dipancarkan oleh matahari dan diterima oleh permukaan bumi setelah melalui berbagai proses interaksi di atmosfer. Selama perjalanannya menuju permukaan bumi, radiasi

matahari mengalami proses absorpsi, refleksi, dan hamburan oleh molekul udara, aerosol, maupun awan di atmosfer (Iqbal, 1983).

Radiasi matahari yang mencapai permukaan bumi terdiri atas beberapa komponen utama, yaitu *Direct Normal Irradiance* (DNI), *Diffuse Horizontal Irradiance* (DHI), dan radiasi pantulan. DNI merupakan radiasi matahari langsung yang diterima permukaan bumi tanpa mengalami hamburan atmosfer, sedangkan DHI merupakan radiasi matahari yang telah mengalami hamburan sebelum mencapai permukaan bumi (Duffie & Beckman, 2013).

Kombinasi antara radiasi langsung dan radiasi difus menghasilkan total radiasi matahari yang diterima oleh permukaan horizontal bumi yang dikenal sebagai *Global Horizontal Irradiance* (GHI). Parameter ini menjadi salah satu indikator utama dalam analisis potensi energi surya karena berkaitan langsung dengan energi yang dapat dikonversi oleh sistem fotovoltaik (Yildirim et al., 2023).

2.1.3 Global Horizontal Irradiance (GHI)

Global Horizontal Irradiance (GHI) merupakan jumlah total radiasi matahari yang diterima oleh permukaan horizontal bumi dalam satuan watt per meter persegi (W/m^2). Secara umum, GHI merupakan kombinasi dari radiasi langsung yang diproyeksikan pada permukaan horizontal serta radiasi difus yang tersebar di atmosfer (Meddahi et al., 2025; Suratno & Cahyono, 2023).

Secara matematis, hubungan antara komponen radiasi matahari dapat dinyatakan sebagai berikut:

$$GHI = DNI \times \cos(\theta_z) + DHI \quad (2.1.3.1)$$

dimana;

GHI = Global Horizontal Irradiance

DNI = Direct Normal Irradiance

DHI = Diffuse Horizontal Irradiance

θ_z = Sudut zenith matahari

Nilai GHI memiliki peranan penting dalam berbagai analisis sistem energi surya, khususnya dalam perencanaan dan optimasi pembangkit listrik tenaga surya. Oleh karena itu, pengembangan metode prediksi GHI yang akurat menjadi salah satu

topik penting dalam bidang energi terbarukan dan kecerdasan buatan (J. Huang et al., 2020).

2.1.4 Variabilitas Musiman Radiasi Matahari

Radiasi matahari yang diterima oleh permukaan bumi tidak bersifat konstan, melainkan mengalami variasi yang dipengaruhi oleh berbagai faktor seperti posisi matahari, kondisi atmosfer, serta perubahan musim sepanjang tahun. Variasi ini menyebabkan intensitas radiasi matahari yang diterima pada suatu lokasi dapat berbeda pada waktu yang berbeda (Iqbal, 1983).

Di wilayah tropis seperti Indonesia, pola radiasi matahari sangat dipengaruhi oleh musim hujan dan musim kemarau yang berkaitan dengan sistem angin monsun. Pada musim hujan, intensitas radiasi matahari cenderung menurun akibat meningkatnya tutupan awan dan kelembapan udara. Sebaliknya, pada musim kemarau kondisi atmosfer relatif lebih cerah sehingga radiasi matahari yang diterima permukaan bumi cenderung lebih tinggi (Zhang et al., 2022).

Variabilitas musiman tersebut menjadi faktor penting dalam prediksi radiasi matahari karena dapat memengaruhi performa model prediksi. Model yang mampu menangkap pola musiman secara baik akan menghasilkan performa prediksi yang lebih stabil pada berbagai kondisi atmosfer.

2.1.5 Prediksi Radiasi Matahari

Prediksi radiasi matahari merupakan proses memperkirakan nilai radiasi matahari pada waktu yang akan datang berdasarkan data historis maupun parameter meteorologi lainnya. Prediksi ini memiliki peranan penting dalam sistem energi surya karena dapat membantu proses pengelolaan distribusi energi, optimasi operasi pembangkit listrik tenaga surya, serta menjaga stabilitas sistem kelistrikan (Voyant et al., 2017).

Metode prediksi radiasi matahari secara umum dapat diklasifikasikan menjadi tiga kelompok utama, yaitu metode fisika, metode statistik, dan metode berbasis *machine learning* maupun *deep learning*. Metode statistik seperti *Autoregressive Integrated Moving Average* (ARIMA) banyak digunakan pada penelitian awal prediksi radiasi matahari. Namun, metode statistik memiliki keterbatasan dalam

memodelkan hubungan nonlinier dan pola temporal yang kompleks pada data radiasi matahari (Zhang et al., 2022).

Perkembangan teknologi komputasi menyebabkan pendekatan berbasis *machine learning* dan *deep learning* semakin banyak digunakan dalam prediksi radiasi matahari. Pendekatan ini mampu mempelajari hubungan nonlinier antarvariabel serta menangkap pola temporal secara lebih efektif dibandingkan metode konvensional (Alkhatib et al., 2025).

2.1.6 Deep Learning

Deep learning merupakan bagian dari *machine learning* yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan (*deep neural network*) untuk mempelajari representasi data secara hierarkis. Pendekatan ini mampu mengekstraksi pola kompleks secara otomatis dari data dalam jumlah besar sehingga banyak digunakan pada berbagai bidang seperti computer vision, *natural language processing*, dan prediksi time series (Goodfellow et al., 2016).

Dalam konteks data time series, *deep learning* memiliki kemampuan untuk menangkap hubungan nonlinier dan dependensi temporal yang kompleks. Salah satu arsitektur deep learning yang banyak digunakan untuk data time series adalah *Recurrent Neural Network* (RNN) dan variannya seperti *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU) (Wang et al., 2020).

Pada prediksi radiasi matahari, berbagai arsitektur deep learning telah banyak dikembangkan untuk meningkatkan akurasi prediksi. Beberapa model yang umum digunakan antara lain *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), *Gated Recurrent Unit* (GRU), *Bidirectional LSTM* (BiLSTM), serta model hybrid seperti CNN-LSTM. Di antara berbagai arsitektur tersebut, LSTM menjadi salah satu model yang paling banyak digunakan karena mampu mengatasi permasalahan *vanishing gradient* pada RNN serta memiliki kemampuan dalam menangkap dependensi temporal jangka panjang pada data time series (Hochreiter & Schmidhuber, 1997).

Dibandingkan metode statistik maupun machine learning konvensional, *deep learning* menunjukkan performa yang lebih baik terutama pada data yang bersifat kompleks, nonlinier, dan tidak stasioner. Hal tersebut disebabkan karena model


deep learning mampu mempelajari pola data secara otomatis tanpa memerlukan proses *feature extraction* manual yang kompleks. Beberapa penelitian menunjukkan bahwa model LSTM mampu menghasilkan akurasi prediksi yang lebih tinggi dibandingkan *Artificial Neural Network* (ANN) maupun metode tradisional lainnya dalam prediksi radiasi matahari jangka pendek (Abdel-Nasser & Mahmoud, 2019).

Dalam konteks prediksi radiasi matahari, penggunaan metode *deep learning* terbukti mampu meningkatkan performa prediksi secara signifikan. Studi review yang dilakukan oleh Voyant et al. (2017) menunjukkan bahwa pendekatan *machine learning* dan *deep learning* memberikan hasil prediksi yang lebih baik dibandingkan metode konvensional. Selain itu, penelitian terbaru pada wilayah tropis juga menunjukkan bahwa karakteristik atmosfer yang kompleks memerlukan pendekatan berbasis *deep learning* agar model mampu menangkap dinamika radiasi matahari secara lebih optimal (Suwadana et al., 2025).

2.1.7 Long Short-Term Memory (LSTM)

Long Short-Term Memory merupakan salah satu jenis jaringan saraf tiruan yang termasuk dalam kategori *Recurrent Neural Network* (RNN). Metode ini dirancang untuk memproses data deret waktu dengan memanfaatkan mekanisme memori yang memungkinkan metode menyimpan informasi dari data historis dalam jangka waktu yang panjang (Hochreiter & Schmidhuber, 1997).

LSTM terdiri dari tiga komponen utama yaitu *forget gate*, *input gate*, dan *output gate*. Ketiga komponen ini bekerja untuk mengontrol aliran informasi pada *cell state* sehingga model dapat mempertahankan informasi penting dan membuang informasi yang tidak relevan. Hal ini memungkinkan LSTM untuk menangkap pola temporal jangka panjang pada data time series, yang dijelaskan dalam gambar 2.1.



Gambar 2.1 Gambar Blok LSTM

Secara matematis, operasi LSTM pada waktu ke-t dapat dirumuskan sebagai:

1. Forget Gate

Menentukan apa yang dibuang dari memori:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.1.7.1)$$

Dimana:

f_t = nilai forget (0 – 1)

kalau mendekati 0 → dilupakan

kalau mendekati 1 → disimpan

2. Input Gate

Menentukan informasi baru yang masuk:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.1.7.2)$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (2.1.7.3)$$

arti:

- i_t = seberapa banyak info baru dipakai
- $\tilde{c}_t$ = kandidat memori baru

3. Update Cell State

Gabungan lama + baru

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (2.1.7.4)$$

inti memori LSTM

4. *Output Gate*

Menentukan output:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.1.7.5)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (2.1.7.6)$$

dimana;

X_t : input pada waktu ke-t

H_t : hidden state pada waktu ke-t

C_t : cell state pada waktu ke-t

σ : fungsi sigmoid

$\tanh$: fungsi hyperbolic tangent

W dan b : bobot dan bias model

Kemampuan LSTM dalam mempelajari pola temporal membuat model ini banyak digunakan dalam prediksi data time series, termasuk prediksi radiasi matahari jangka pendek. Berbagai penelitian menunjukkan bahwa model LSTM mampu menghasilkan performa prediksi yang baik karena mampu menangkap pola historis dan dinamika temporal data radiasi matahari (Yildirim et al., 2023).

2.1.8 Multivariate Long Short-Term Memory (M-LSTM)

Multivariate Long Short-Term Memory (M-LSTM) merupakan pengembangan dari model LSTM yang digunakan untuk memproses data time series dengan lebih dari satu variabel input. Berbeda dengan pendekatan univariat yang hanya menggunakan satu variabel utama, M-LSTM memanfaatkan beberapa variabel yang saling berkaitan untuk meningkatkan kemampuan prediksi model (Sorkun et al., 2020).

Dalam prediksi *Global Horizontal Irradiance* (GHI), pendekatan multivariat menjadi penting karena nilai GHI tidak hanya dipengaruhi oleh nilai historisnya sendiri, tetapi juga dipengaruhi oleh berbagai faktor lain seperti *Direct Normal*

Irradiance (DNI), *Diffuse Horizontal Irradiance* (DHI), parameter geometri matahari, serta faktor meteorologi dan temporal (Alharbi & Csala, 2021). Variabel meteorologi seperti suhu, kelembapan udara, dan kondisi atmosfer juga diketahui memiliki kontribusi signifikan terhadap perubahan nilai GHI (Zhang et al., 2024).


Secara umum, struktur input pada multivariat LSTM dapat direpresentasikan dalam bentuk matriks tiga dimensi, yaitu jumlah sampel, panjang waktu (*time step*), dan jumlah fitur. Misalnya, jika digunakan beberapa variabel input seperti GHI, DNI, diffuse, Azimuth, Elevasi, serta fitur waktu, maka setiap langkah waktu akan memiliki sejumlah fitur yang diproses secara simultan oleh model LSTM.

Pendekatan M-LSTM memungkinkan model mempelajari pola temporal sekaligus hubungan antarvariabel dalam satu proses pembelajaran. Hal ini berbeda dengan pendekatan univariat yang hanya memanfaatkan satu variabel sehingga memiliki keterbatasan dalam menangkap dinamika sistem yang kompleks. Penelitian sebelumnya menunjukkan bahwa penggunaan M-LSTM mampu meningkatkan akurasi prediksi dibandingkan model univariat karena model memperoleh informasi tambahan dari variabel lain yang relevan (Delgado et al., 2024; Sorkun et al., 2020).

Selain itu, Multivariate LSTM juga memiliki keunggulan dalam memodelkan data yang bersifat nonlinier dan tidak stasioner, seperti data radiasi matahari yang dipengaruhi oleh kondisi cuaca yang dinamis (Tsai & Lo, 2025). Dengan memanfaatkan memori jangka panjang, model mampu mempertahankan informasi historis penting untuk meningkatkan performa prediksi.

Dalam penelitian ini, model M-LSTM digunakan untuk memprediksi nilai *Global Horizontal Irradiance* (GHI) satu jam ke depan menggunakan beberapa variabel input, yaitu GHI, DNI, DHI, Azimuth, elevasi, serta fitur temporal seperti hour dan day of year. Pemilihan variabel tersebut didasarkan pada hubungan fisik dan temporal yang kuat terhadap perubahan nilai GHI, sehingga diharapkan mampu meningkatkan performa prediksi model berbasis deep learning (Khan et al., 2025). Sebelum dimasukkan ke dalam model, data terlebih dahulu diproses menggunakan metode *sliding window* untuk membentuk struktur data time series.

Dengan pendekatan multivariat, model diharapkan mampu menghasilkan prediksi GHI yang lebih akurat karena dapat memanfaatkan hubungan antarvariabel dan pola temporal secara simultan. Diagram arsitektur model M-LSTM ditunjukkan pada Gambar 2.2.



Gambar 2.2 Gambar Blok Multivariat LSTM

Rumus Multivariate Long Short-Term Memory (LSTM)

Pada Multivariate LSTM, setiap input pada waktu ke-t tidak lagi berupa satu nilai, tetapi berupa vektor multivariat yang terdiri dari beberapa fitur:

$$\mathbf{x}_t = [x_{t1}, x_{t2}, x_{t3}, \dots, x_{tn}] \quad (2.1.8.1)$$

di mana:

$\mathbf{x}_t$ = vektor input pada waktu ke-t

n = jumlah variabel (fitur), misalnya: GHI, DNI, diffuse, Azimuth, Elevasi, dll

1. Forget Gate

$$f_t = \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + b_f) \quad (2.1.8.2)$$

2. Input Gate

$$i_t = \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + b_i) \quad (2.1.8.3)$$

3. Candidate Cell State

$$\tilde{C}_t = \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + b_c) \quad (2.1.8.4)$$

4. Update Cell State

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (2.1.8.5)$$

5. Output Gate

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (2.1.8.6)$$

6. Hidden State (Output M-LSTM)

$$h_t = o_t \odot \tanh(C_t) \quad (2.1.8.7)$$

Keterangan variabel:

- x_t : vektor input multivariat
- h_t : hidden state
- C_t : cell state
- W dan U : matriks bobot (weight matrix)
- b : bias
- σ : fungsi sigmoid
- $\tanh$: fungsi aktivasi hyperbolic tangent
- $\odot$: perkalian elemen-wise

Perbedaan utama antara M-LSTM dan LSTM univariat terletak pada bentuk input yang digunakan. Pada M-LSTM, setiap gate memproses beberapa fitur secara simultan sehingga model mampu menangkap hubungan antarvariabel dan pola temporal dalam satu waktu. Dengan memanfaatkan informasi tambahan seperti DNI, DHI, Reflektive, Nett Radiation, Azimuth, elevasi, dan fitur temporal, model diharapkan mampu meningkatkan akurasi prediksi Global Horizontal Irradiance (GHI).

2.2 Penelitian Terdahulu

Penelitian mengenai prediksi *Global Horizontal Irradiance* (GHI) telah berkembang pesat dalam beberapa tahun terakhir seiring meningkatnya kebutuhan terhadap sistem energi surya yang andal dan efisien. Berbagai pendekatan berbasis *machine learning* dan *deep learning* telah dikembangkan untuk meningkatkan akurasi prediksi radiasi matahari, khususnya pada prediksi jangka pendek. Salah satu pendekatan yang paling banyak digunakan adalah *Long Short-Term Memory*

(LSTM) karena memiliki kemampuan dalam menangkap pola temporal pada data time series.

Berbagai penelitian menunjukkan bahwa model deep learning mampu menghasilkan performa yang lebih baik dibandingkan metode statistik konvensional. Alkhatib et al. (2025) membandingkan beberapa model deep learning seperti LSTM, CNN, dan CNN-LSTM menggunakan dataset GHI dari tiga kota di Amerika Serikat. Hasil penelitian menunjukkan bahwa model CNN-LSTM menghasilkan performa terbaik dengan nilai koefisien determinasi (R^2) mencapai 0.994. Penelitian tersebut menunjukkan bahwa kombinasi beberapa arsitektur deep learning mampu meningkatkan akurasi prediksi GHI secara signifikan.

Tabel 2.1 Tabel Penelitian terdahulu

No	Peneliti & Tahun	Permasalahan	Dataset / Eksperimen	Metode	Hasil
1	(Alkhatib et al., 2025)	Secara umum, prediksi GHI masih memiliki error tinggi. Secara khusus, perlu dibandingkan model DL terbaik	Data GHI dari 3 kota di USA dengan pembagian train-test	LSTM, CNN, CNN-LSTM	CNN- LSTM memberikan akurasi tertinggi dengan R^2 hingga 0.994
2	(Bedoya et al., 2025)	Variabilitas irradiance menyebabkan ketidakstabilan sistem energi	Dataset meteorologi dari Cuenca, Ecuador	LSTM, Random Forest, Extra Trees	LSTM menghasilkan prediksi paling stabil dibanding metode lain yaitu RMSE: ± 150 W/m ² R^2 : 0.70–0.71

No	Peneliti & Tahun	Permasalahan	Dataset / Eksperimen	Metode	Hasil
3	(Bektas & Altas, 2024)	Prediksi radiasi matahari belum optimal karena pola nonlinier	Data GHI dan parameter meteorologi	DWT + BiLSTM	BiLSTM menghasilkan error lebih kecil dibanding LSTM biasa, RMSE: $\pm 50 - 53 \text{ W/m}^2$ MAE: $\pm 27 - 28 \text{ W/m}^2$
4	(Delgado et al., 2024)	Variasi cuaca menyebabkan ketidakpastian prediksi	Dataset DKA Solar Center	HMM + LSTM multivariate	RMSE sangat kecil (4.65×10^{-4}), MAE 4.04×10^{-4}
5	(Kaysal et al., 2025)	Ketidakpastian radiasi matahari tinggi	Dataset multivariate di Turki	LSTM-GRU hybrid	Error lebih rendah dibanding model tunggal dimana RMSE ≈ 5.7
6	(Neshat et al., 2023)	Data irradiance memiliki sifat sangat kompleks dan stochastic	Data buoy meteorologi	ResNet + LSTM + GRU	Model hybrid memberikan performa terbaik yaitu RMSE terbaik ≈ 0.12 (model CNN-LSTM) R^2 (R-value) ≈ 0.75
7	(Sorkun et al., 2020)	Model univariate tidak cukup akurat	Dataset meteorologi multivariat	Multivariate LSTM	Hasil menunjukkan multivariate lebih unggul NRMSE =

No	Peneliti & Tahun	Permasalahan	Dataset / Eksperimen	Metode	Hasil
8	(Zuo et al., 2022)	Prediksi jangka pendek sangat dipengaruhi oleh awan	Data cloud image + meteorologi	LSTM + cloud detection	0.159 itu untuk univariat NRMSE =0.213 nRMSE 15.25% dan lebih baik dari model baseline Hasil menunjukkan multivariate lebih unggul NRMSE = 0.159 itu untuk univariat NRMSE =0.213
9	(Tsai & Lo, 2025)	Banyak fitur meningkatkan kompleksitas model	Data meteorologi Taiwan (2018–2023)	LSTM + SHAP	Model memberikan akurasi tinggi dimana RMSE GHI: 7.8 R ² : 99%
10	(Alharbi & Csala, 2021)	Fluktuasi energi menyebabkan prediksi sulit	Data GHI, DNI, DHI (1985–2021)	BiLSTM	

Penelitian lain oleh Bedoya et al. (2025) menggunakan dataset meteorologi dari Cuenca, Ecuador untuk membandingkan model LSTM, Random Forest, dan Extra Trees. Hasil penelitian menunjukkan bahwa model LSTM menghasilkan prediksi yang lebih stabil dibandingkan metode lainnya dengan nilai RMSE sekitar ± 150 W/m² dan R² sebesar 0.70–0.71. Penelitian ini menunjukkan bahwa model LSTM memiliki kemampuan yang baik dalam memodelkan data radiasi matahari yang bersifat dinamis dan nonlinier.

Selain model LSTM konvensional, beberapa penelitian juga mengembangkan pendekatan hybrid untuk meningkatkan performa prediksi. Bektas dan Altas (2024) mengombinasikan Discrete Wavelet Transform (DWT) dengan Bidirectional LSTM (BiLSTM) untuk menangkap pola nonlinier pada data radiasi matahari. Hasil penelitian menunjukkan bahwa model DWT-BiLSTM mampu menghasilkan error yang lebih rendah dibandingkan LSTM biasa dengan nilai RMSE sekitar $\pm 50\text{--}53 \text{ W/m}^2$ dan MAE sekitar $\pm 27\text{--}28 \text{ W/m}^2$. Pendekatan hybrid tersebut mampu meningkatkan performa prediksi, namun memiliki kompleksitas preprocessing yang lebih tinggi.

Pendekatan hybrid lainnya dilakukan oleh Delgado et al. (2024) yang menggabungkan Hidden Markov Model (HMM) dengan Multivariate LSTM menggunakan dataset dari DKA Solar Center. Hasil penelitian menunjukkan bahwa model tersebut mampu menghasilkan nilai RMSE yang sangat kecil, yaitu sebesar 4.65×10^{-4} . Penelitian ini menunjukkan bahwa penggunaan preprocessing probabilistik dan pendekatan multivariat mampu meningkatkan performa prediksi secara signifikan, meskipun kompleksitas model menjadi lebih tinggi.

Penelitian oleh Kaysal et al. (2025) juga menunjukkan bahwa penggunaan model hybrid LSTM-GRU mampu menghasilkan performa yang lebih baik dibandingkan model tunggal pada dataset multivariat di Turki. Hasil penelitian menunjukkan bahwa model hybrid menghasilkan nilai RMSE sekitar 5.7. Namun demikian, model hybrid memiliki kompleksitas komputasi yang lebih besar dan berpotensi mengalami overfitting apabila tidak dilakukan tuning parameter secara optimal.

Selain pendekatan hybrid, beberapa penelitian juga menekankan pentingnya penggunaan variabel multivariat dalam prediksi GHI. Sorkun et al. (2020) menunjukkan bahwa model Multivariate LSTM menghasilkan performa yang lebih baik dibandingkan model univariat dengan nilai NRMSE sebesar 0.159, sedangkan model univariat menghasilkan NRMSE sebesar 0.213. Hasil tersebut menunjukkan bahwa penggunaan beberapa variabel input mampu meningkatkan kemampuan model dalam menangkap hubungan antarvariabel dan pola temporal secara lebih efektif.

Penelitian oleh Tsai dan Lo (2025) menggunakan pendekatan LSTM yang dikombinasikan dengan SHAP untuk melakukan interpretasi model dan seleksi fitur pada data meteorologi Taiwan periode 2018–2023. Hasil penelitian menunjukkan bahwa pengurangan fitur tertentu tetap mampu menghasilkan performa prediksi yang baik. Penelitian ini menunjukkan bahwa pemilihan fitur yang relevan memiliki pengaruh penting terhadap performa model deep learning.

Selain faktor model, beberapa penelitian juga mempertimbangkan pengaruh faktor eksternal seperti kondisi awan terhadap akurasi prediksi. Zuo et al. (2022) menggunakan citra awan dan data meteorologi pada model LSTM berbasis cloud detection untuk prediksi GHI jangka pendek. Hasil penelitian menunjukkan bahwa model tersebut mampu mencapai nilai nRMSE sebesar 15.25% dan menghasilkan performa yang lebih baik dibandingkan model baseline. Penelitian ini menunjukkan bahwa faktor atmosfer memiliki pengaruh yang signifikan terhadap perubahan nilai GHI.

Penelitian lain oleh Alharbi dan Csala (2021) menggunakan Bidirectional LSTM (BiLSTM) untuk memprediksi radiasi matahari menggunakan dataset jangka panjang yang mencakup GHI, DNI, dan DHI dari tahun 1985–2021. Hasil penelitian menunjukkan bahwa model BiLSTM mampu menghasilkan akurasi tinggi dengan nilai RMSE sebesar 7.8 dan koefisien determinasi (R^2) mencapai 99%. Penggunaan BiLSTM memungkinkan model mempelajari dependensi temporal dari dua arah waktu sehingga mampu meningkatkan performa prediksi.

Berdasarkan berbagai penelitian tersebut, dapat disimpulkan bahwa model LSTM dan variannya merupakan pendekatan yang efektif dalam prediksi Global Horizontal Irradiance (GHI), terutama ketika menggunakan pendekatan multivariat. Model hybrid terbukti mampu meningkatkan akurasi prediksi, namun memiliki kompleksitas model dan kebutuhan komputasi yang lebih tinggi. Selain itu, sebagian besar penelitian sebelumnya masih menggunakan dataset resolusi rendah dan dilakukan pada wilayah subtropis. Penelitian yang menggunakan data resolusi tinggi serta mempertimbangkan karakteristik wilayah tropis seperti Indonesia masih relatif terbatas. Oleh karena itu, masih terdapat peluang penelitian untuk mengkaji perbandingan model LSTM dan Multivariate LSTM menggunakan

data resolusi tinggi pada wilayah tropis serta menganalisis pengaruh musim terhadap performa prediksi GHI.

2.3 Research Gap

Berdasarkan tinjauan penelitian terdahulu, dapat diidentifikasi beberapa kesenjangan (*research gap*) dalam penelitian prediksi *Global Horizontal Irradiance* (GHI).

Pertama, berbagai penelitian menunjukkan bahwa model Long Short-Term Memory (LSTM) dan variannya mampu menghasilkan performa prediksi yang baik pada data time series radiasi matahari. Pendekatan multivariat juga terbukti mampu meningkatkan akurasi prediksi dibandingkan pendekatan univariat karena memanfaatkan informasi tambahan dari beberapa variabel input (Sorkun et al., 2020). Namun demikian, penelitian yang secara khusus melakukan perbandingan langsung antara model LSTM univariat dan Multivariate LSTM (M-LSTM) menggunakan konfigurasi eksperimen yang seragam masih relatif terbatas.

Kedua, beberapa penelitian mengembangkan model hybrid seperti CNN-LSTM, BiLSTM, dan kombinasi preprocessing lanjutan untuk meningkatkan performa prediksi. (Kaysal et al., 2025; Tsai & Lo, 2025) Meskipun pendekatan tersebut mampu menghasilkan akurasi yang tinggi, kompleksitas model dan kebutuhan komputasi menjadi lebih besar sehingga implementasinya menjadi kurang efisien pada beberapa kondisi. Oleh karena itu, diperlukan penelitian yang mengevaluasi model dengan arsitektur yang lebih sederhana namun tetap mampu menghasilkan performa prediksi yang optimal, seperti perbandingan antara LSTM dan M-LSTM.

Ketiga, sebagian besar penelitian sebelumnya masih menggunakan dataset dengan resolusi temporal rendah, seperti data per jam atau harian. Penggunaan data resolusi tinggi, khususnya data per menit, masih relatif jarang dilakukan. Padahal, data resolusi tinggi mampu memberikan informasi temporal yang lebih detail dan berpotensi meningkatkan kemampuan model dalam menangkap dinamika perubahan radiasi matahari secara lebih akurat (Delgado et al., 2024; Kaysal et al., 2025)

Keempat, mayoritas penelitian prediksi GHI dilakukan pada wilayah subtropis atau negara dengan karakteristik iklim yang berbeda dengan wilayah tropis. Penelitian pada wilayah tropis seperti Indonesia masih relatif terbatas, padahal wilayah tropis memiliki variabilitas atmosfer yang tinggi akibat pengaruh tutupan awan, kelembapan udara, dan pola musim yang dinamis. Kondisi tersebut menyebabkan prediksi radiasi matahari pada wilayah tropis memiliki tingkat kompleksitas yang lebih tinggi dibandingkan wilayah subtropis.

Kelima, penelitian yang menganalisis pengaruh musim terhadap performa model prediksi GHI juga masih belum banyak dilakukan. Sebagian besar penelitian hanya berfokus pada peningkatan akurasi model tanpa mengevaluasi bagaimana perubahan kondisi atmosfer pada musim hujan dan musim kemarau mempengaruhi performa prediksi.

Berdasarkan berbagai research gap tersebut, penelitian ini berfokus pada perbandingan model LSTM dan Multivariate LSTM (M-LSTM) menggunakan data radiasi matahari resolusi tinggi pada wilayah tropis. Selain itu, penelitian ini juga menganalisis pengaruh penggunaan variabel multivariat dan variabilitas musim terhadap performa prediksi Global Horizontal Irradiance (GHI).

2.4 Hipotesis

Berdasarkan landasan teori dan hasil penelitian terdahulu, hipotesis dalam penelitian ini adalah sebagai berikut:

H1 : Model *Multivariate Long Short-Term Memory* (M-LSTM) memiliki performa prediksi yang lebih baik dibandingkan model *Long Short-Term Memory* (LSTM) dalam prediksi *Global Horizontal Irradiance* (GHI).

H2 : Penggunaan variabel multivariat seperti *DNI*, *DHI*, *Reflective Radiation*, *Net Radiation*, *Azimuth*, *Elevation*, serta fitur temporal berpengaruh terhadap peningkatan akurasi prediksi *Global Horizontal Irradiance* (GHI).

H3 : Variabilitas musim hujan dan musim kemarau mempengaruhi performa model prediksi *Global Horizontal Irradiance* (GHI).

BAB III

METODOLOGI PENELITIAN

3.1 Kerangka Konsep Penelitian

Kerangka konsep penelitian ini menggambarkan hubungan antara data input, proses pengolahan data, model prediksi, serta output yang dihasilkan dalam proses prediksi Global Horizontal Irradiance (GHI). Kerangka konsep digunakan untuk memberikan gambaran sistematis mengenai alur penelitian mulai dari pengumpulan data hingga evaluasi performa model.

Penelitian ini menggunakan data radiasi matahari dan variabel meteorologi sebagai data input. Variabel yang digunakan meliputi Global Horizontal Irradiance (GHI), Direct Normal Irradiance (DNI), Diffuse Horizontal Irradiance (DHI), Reflective Radiation, Net Radiation, Azimuth, Elevation, serta fitur temporal seperti hour dan day of year. Variabel tersebut dipilih karena memiliki hubungan fisik dan temporal yang kuat terhadap perubahan nilai GHI.


Tahap selanjutnya adalah preprocessing data yang meliputi data cleaning, penanganan missing value, normalisasi data, dan pembentukan fitur (feature engineering). Setelah preprocessing selesai dilakukan, data time series dibentuk menggunakan metode sliding window untuk menghasilkan struktur input yang sesuai dengan kebutuhan model deep learning.

Data yang telah diproses kemudian digunakan pada dua model prediksi, yaitu Long Short-Term Memory (LSTM) sebagai model baseline dan Multivariate Long Short-Term Memory (M-LSTM) sebagai model utama. Model LSTM digunakan untuk mempelajari pola temporal berdasarkan satu variabel utama, sedangkan model M-LSTM memanfaatkan beberapa variabel input secara simultan untuk menangkap hubungan temporal dan hubungan antarvariabel yang lebih kompleks (Sorkun et al., 2020).

Output dari kedua model berupa prediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan. Hasil prediksi kemudian dievaluasi menggunakan beberapa metrik evaluasi, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Coefficient of Determination (R^2). Perbandingan hasil evaluasi

digunakan untuk menganalisis performa kedua model serta menentukan efektivitas pendekatan multivariat dalam meningkatkan akurasi prediksi GHI.

Diagram kerangka konsep penelitian ditunjukkan pada Gambar 3.1.



Gambar 3.1 Diagram Kerangka Konsep Penelitian

3.2 Desain Penelitian

Penelitian ini menggunakan pendekatan kuantitatif berbasis *deep learning* untuk memprediksi nilai **Global Horizontal Irradiance (GHI)** satu jam ke depan menggunakan data *time series* radiasi matahari. Pendekatan kuantitatif dipilih karena penelitian berfokus pada pengukuran performa model prediksi berdasarkan data numerik serta evaluasi statistik yang dilakukan secara objektif. Data yang digunakan berupa data radiasi matahari resolusi tinggi dengan interval pengamatan satu menit yang diperoleh dari sistem pengukuran radiasi matahari di Stasiun Klimatologi Jawa Timur, Kota Malang.

Model yang digunakan dalam penelitian ini adalah **Long Short-Term Memory (LSTM)** sebagai model baseline dan **Multivariate Long Short-Term Memory (M-LSTM)** sebagai model utama. Model LSTM memanfaatkan data historis GHI sebagai input tunggal untuk mempelajari pola temporal dalam data radiasi matahari. Sementara itu, model M-LSTM menggunakan beberapa variabel input secara simultan, yaitu Global Horizontal Irradiance (GHI), Direct Normal Irradiance (DNI), Diffuse Horizontal Irradiance (DHI), Reflective Radiation, Net Radiation, Azimuth, Elevation, serta fitur temporal berupa *hour* dan *day of year*. Penggunaan pendekatan multivariat diharapkan mampu menangkap hubungan temporal sekaligus hubungan antarvariabel yang memengaruhi perubahan nilai GHI sehingga dapat meningkatkan akurasi prediksi.

Pendekatan *deep learning* dipilih karena memiliki kemampuan dalam memodelkan hubungan nonlinier dan pola temporal yang kompleks pada data *time series*. Selain itu, arsitektur LSTM dirancang untuk mengatasi permasalahan *vanishing gradient* yang umum terjadi pada Recurrent Neural Network (RNN), sehingga mampu mempertahankan informasi penting dalam rentang waktu yang panjang (Hochreiter & Schmidhuber, 1997). Kemampuan tersebut menjadikan LSTM dan variannya banyak digunakan dalam penelitian prediksi radiasi matahari jangka pendek serta berbagai aplikasi prediksi berbasis data sekuensial.

Secara umum, penelitian ini terdiri atas beberapa tahapan utama yang meliputi pengumpulan data (*data collection*), persiapan data (*data preparation*), perancangan sistem (*system design*), pelaksanaan eksperimen, evaluasi model, dan

analisis hasil. Tahap persiapan data mencakup proses *data cleaning*, *feature engineering*, normalisasi data menggunakan metode Min-Max Scaling, pembentukan data *time series* menggunakan metode *sliding window*, serta pembagian dataset menjadi data pelatihan, validasi, dan pengujian. Selanjutnya, data yang telah diproses digunakan untuk melatih model LSTM dan M-LSTM guna menghasilkan prediksi nilai GHI satu jam ke depan.

Performa kedua model dievaluasi menggunakan metrik **Root Mean Square Error (RMSE)**, **Mean Absolute Error (MAE)**, dan **Coefficient of Determination (R^2)**. Hasil evaluasi kemudian dibandingkan untuk menentukan model yang memiliki performa terbaik dalam memprediksi radiasi matahari. Selain itu, penelitian ini juga menganalisis pengaruh kondisi musim hujan dan musim kemarau terhadap karakteristik radiasi matahari serta performa model prediksi. Rangkaian tahapan penelitian secara keseluruhan disajikan dalam desain sistem dan alur penelitian yang ditunjukkan pada bagian berikutnya.

3.2.1 Data Collection

Dataset yang digunakan dalam penelitian ini merupakan data radiasi matahari dengan resolusi temporal satu menit selama periode 1 Mei 2025 hingga 30 April 2026. Data diperoleh dari *Automatic Solar Radiation System* (ASRS) yang terpasang pada Stasiun Klimatologi Jawa Timur di Kota Malang, Indonesia. Sistem ini melakukan pengukuran radiasi matahari secara otomatis dan kontinu sehingga mampu menghasilkan data dengan resolusi temporal tinggi yang sesuai untuk pengembangan model prediksi berbasis *time series*.

ASRS merupakan sistem pengukuran radiasi matahari yang terintegrasi dengan berbagai sensor dan perangkat akuisisi data otomatis. Sistem ini banyak digunakan dalam bidang meteorologi, klimatologi, dan energi terbarukan untuk memantau kondisi radiasi matahari secara real-time (Nugraha & Adriansyah, 2022; Oyelami et al., 2020; Rocha et al., 2021).

Komponen utama ASRS meliputi *pyranometer* untuk mengukur Global Horizontal Irradiance (GHI), *pyrheliometer* untuk mengukur Direct Normal Irradiance (DNI), *shadow ring* untuk pengukuran Diffuse Horizontal Irradiance (DHI), *sun tracker* untuk mengikuti pergerakan matahari, serta *data logger* untuk

menyimpan dan mengelola hasil pengukuran sensor. Lokasi perangkat ASRS yang digunakan dalam penelitian ini ditunjukkan pada gambar 3.2.



Gambar 3.2 Lokasi Penelitian

Secara teoritis, jumlah data yang dihasilkan selama satu tahun pengamatan dapat dihitung berdasarkan resolusi temporal satu menit sebagai berikut:

$$365 \times 24 \times 60 = 525.600$$

Berdasarkan resolusi temporal satu menit, jumlah observasi teoritis sepanjang satu tahun pengamatan adalah sebanyak 525.600 data. Pada kondisi riilnya, dataset mentah yang terekam oleh sistem *ASRS* berjumlah 543.066 data karena adanya duplikasi pencatatan oleh sensor (*high-frequency logging* dan *buffer-retransmit*). Setelah dilakukan proses pengondisian data (*data cleaning*) untuk menghapus rekaman ganda serta data yang tidak valid, jumlah sampel akhir yang digunakan dalam penelitian ini menyusut menjadi **509.473 observasi valid** yang siap digunakan untuk proses *training* dan *testing* model Stacked LSTM.

Lokasi penelitian berada di Jl. Zentana No 33 Ngijo Karangploso Kabupaten Malang, Jawa Timur, Indonesia, yang terletak pada wilayah tropis dengan potensi energi surya yang relatif tinggi sepanjang tahun. Wilayah tropis memiliki karakteristik atmosfer yang dinamis akibat pengaruh tutupan awan, kelembapan

udara, serta perubahan musim yang dapat menyebabkan fluktuasi radiasi matahari. Kondisi tersebut menjadikan prediksi radiasi matahari pada wilayah tropis memiliki tingkat kompleksitas yang cukup tinggi sehingga menarik untuk diteliti menggunakan pendekatan *deep learning*.

Secara umum, Indonesia memiliki dua musim utama, yaitu musim hujan dan musim kemarau. Untuk wilayah Jawa Timur, musim hujan umumnya berlangsung pada periode Oktober hingga April, sedangkan musim kemarau berlangsung pada periode Mei hingga September (Badan Meteorologi dan Geofisika, 2021; Nuraini & Fitri, 2022; Susilo, 2021). Variasi musim tersebut memengaruhi intensitas radiasi matahari yang diterima permukaan bumi akibat perubahan kondisi atmosfer seperti tutupan awan dan kelembapan udara. Oleh karena itu, penelitian ini juga melakukan analisis berdasarkan musim untuk mengevaluasi pengaruh kondisi atmosfer terhadap performa model prediksi Global Horizontal Irradiance (GHI). Analisis dilakukan dengan membandingkan performa model pada periode musim hujan dan musim kemarau guna mengetahui kemampuan model dalam menangkap variabilitas radiasi matahari pada kondisi atmosfer yang berbeda.

3.2.2 Data Preparation

Tahap *data preparation* dilakukan untuk meningkatkan kualitas data sebelum digunakan dalam proses pelatihan model *deep learning*. Proses ini bertujuan untuk menghasilkan dataset yang bersih, konsisten, dan sesuai dengan kebutuhan pemodelan *time series* sehingga mampu meningkatkan kemampuan model dalam mempelajari pola radiasi matahari secara optimal. Selain itu, tahapan ini juga berperan dalam mengurangi pengaruh *noise*, data tidak valid, dan perbedaan skala antarvariabel yang dapat memengaruhi performa model prediksi.

Pada penelitian ini, *data preparation* terdiri atas beberapa tahapan utama, yaitu *data cleaning*, normalisasi data menggunakan metode *Min-Max Scaling*, pembentukan dataset *time series* menggunakan metode *sliding window*, serta pembagian dataset menjadi data pelatihan (*training*), dan pengujian (*testing*).

Seluruh tahapan dilakukan secara berurutan untuk menjaga kualitas data dan menghindari terjadinya *data leakage* selama proses pelatihan dan evaluasi model.


Tahap *data cleaning* dilakukan untuk mengidentifikasi dan menghapus data yang tidak valid, seperti data duplikat, *missing value*, maupun nilai pengukuran yang berada di luar rentang fisik radiasi matahari. Selanjutnya dilakukan normalisasi menggunakan metode *Min-Max Scaling* agar berada pada rentang nilai yang sama. Normalisasi dilakukan untuk mempercepat proses konvergensi dan meningkatkan stabilitas pelatihan model *deep learning*. Data yang telah dinormalisasi kemudian dibentuk menjadi data *time series* menggunakan metode *sliding window* dengan ukuran jendela 30 menit . Proses ini bertujuan untuk membangun hubungan antara data historis dengan nilai target yang akan diprediksi, yaitu nilai Global Horizontal Irradiance (GHI) satu menit ke depan.

Tahap terakhir pada *data preparation* adalah pembagian dataset menjadi data *training*, dan *testing* dengan rasio 80%, dan 20%. Pembagian dilakukan berdasarkan urutan waktu (*time series split*) untuk mempertahankan dependensi temporal data dan mencegah kebocoran informasi antar dataset. Dataset yang telah melalui seluruh tahapan *data preparation* selanjutnya digunakan sebagai input pada proses pengembangan model LSTM dan M-LSTM.

3.2.3 System Design

Sistem yang dikembangkan dalam penelitian ini terdiri atas empat komponen utama, yaitu input, data preparation, model development, dan output. Diagram sistem menggambarkan alur pengolahan data mulai dari pengumpulan data radiasi matahari hingga menghasilkan prediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan menggunakan model LSTM dan M-LSTM.

Berikut merupakan penjelasan setiap langkah pada system design penelitian yang ditunjukkan pada Gambar 3.3.



Gambar 3.3 System design Penelitian

A. Step 1 (Data collection)

Data collection terdiri dari :

1. Variabel Dependen (Terikat)

Variabel dependen dalam penelitian ini adalah:

- Global Horizontal Irradiance (GHI)

Global Horizontal Irradiance (GHI) merupakan total radiasi matahari yang diterima pada permukaan horizontal bumi yang terdiri atas kombinasi radiasi langsung dan radiasi difus. Variabel ini digunakan sebagai target utama dalam proses prediksi karena memiliki peranan penting dalam analisis potensi energi surya.

2. Variabel Independen (Bebas)

Variabel Independent dalam penelitian ini terdiri dari:

- Direct Normal Irradiance (DNI)
- Diffuse Horizontal Irradiance (DHI)
- Reflektive
- Nett Radiation
- Azimuth
- Elevation

Variabel variable yang digunakan dalam penelitian ini terdiri atas *Direct Normal Irradiance* (DNI), *Diffuse Horizontal Irradiance* (DHI), *Reflective*, *Nett Radiation*, Azimuth, dan elevation. Variabel-variabel tersebut dipilih karena memiliki hubungan fisik yang erat dengan pembentukan nilai *Global Horizontal Irradiance* (GHI), sehingga berpotensi meningkatkan kemampuan model dalam mempelajari pola perubahan radiasi matahari. DNI merupakan radiasi matahari langsung yang diterima oleh permukaan yang tegak lurus terhadap arah dari sinar matahari, sedangkan DHI merupakan radiasi yang telah mengalami hamburan di atmosfer sebelum mencapai permukaan bumi. *Reflective Radiation* merepresentasikan radiasi matahari yang dipantulkan oleh permukaan bumi, sedangkan *Net Radiation* menunjukkan keseimbangan energi radiasi yang diterima dan dipancarkan oleh permukaan. Kedua variable tersebut digunakan karena memiliki hubungan fisik dengan perubahan nilai GHI dan berpotensi meningkatkan kemampuan model dalam mempelajari dinamika radiasi matahari. Adapun Azimuth dan elevation menggambarkan posisi matahari terhadap permukaan bumi. Keenam variable tersebut dipilih karena memiliki keterkaitan fisik yang kuat dalam pembentukan nilai GHI, sehingga relevan digunakan sebagai input dalam model prediksi berbasis deep learning.

3. Variabel Waktu

Selain variabel utama, penelitian ini juga mempertimbangkan aspek waktu sebagai bagian dari karakteristik data time series, yang meliputi:

- Waktu pengamatan (timestamp)

Variabel waktu digunakan untuk membantu model dalam menangkap pola temporal, seperti siklus harian dan musiman yang memengaruhi intensitas radiasi matahari.

4. Karakteristik Data

Karakteristik dataset yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Berupa data time series dengan resolusi temporal satu menit
2. Memiliki pola temporal harian dan musiman
3. Dipengaruhi oleh posisi matahari dan kondisi atmosfer
4. Bersifat nonlinier dan dinamis
5. Memiliki dependensi temporal jangka pendek dan jangka panjang

Karakteristik tersebut menyebabkan pendekatan *deep learning* seperti LSTM dan M-LSTM relevan digunakan dalam penelitian ini.

5. Batasan Variabel

Penelitian ini hanya menggunakan variabel radiasi matahari dan parameter geometri matahari yang memiliki hubungan langsung dengan nilai Global Horizontal Irradiance (GHI). Variabel meteorologi tambahan seperti suhu udara, kelembapan relatif, dan kecepatan angin tidak digunakan dalam penelitian ini karena keterbatasan data serta untuk menjaga kompleksitas model agar tetap efisien.

Selain itu, target prediksi dalam penelitian ini adalah nilai *Global Horizontal Irradiance* (GHI) satu jam ke depan.

Data set yang dipergunakan dijelaskan dalam Tabel 3.1

Tabel 3. 1 Dataset Penelitian

Variabel	Deskripsi
Timestamp	Waktu pengamatan
GHI	<i>Global Horizontal Irradiance</i>
DHI	<i>Diffuse Horizontal Irradiance</i>
DNI	<i>Direct Normal Irradiance</i>
Reflective	Radiasi pantulan
Nett_Rad	Radiasi bersih
Azimuth	Sudut Azimuth matahari
Elevation	Sudut Elevation

No	Timestamp	GHI	Diffuse	DNI	Reflective	Net_Rad	Azimuth	Elevasi
1	2025-05-01 00:00:00	0	0	0	0.6	-0.6	0	-15
2	2025-05-01 00:01:00	0	0	0	1	-1	0	-15
3	2025-05-01 00:02:00	0	0	0	1	-1	0	-15
4	2025-05-01 00:03:00	0	0	0	1	-1	0	-15
5	2025-05-01 00:04:00	0	0	0	1	-1	0	-15
6	2025-05-01 00:05:00	0	0	0	1	-1	0	-15
340	2025-05-01 05:39:00	7.7	7.3	0	2.1	5.7	74.7	1.1
341	2025-05-01 05:40:00	8.5	8	0	2.9	5.7	74.6	1.3
342	2025-05-01 05:41:00	9.6	9.2	0	2.9	6.7	74.6	1.5
343	2025-05-01 05:42:00	10.8	10.4	0	2.9	7.9	74.6	1.7
344	2025-05-01 05:43:00	12	11.5	0	3.3	8.7	74.5	1.9
D	-	-	-	-	-	-	-	-
S	-	-	-	-	-	-	-	-
T	-	-	-	-	-	-	-	-
509468	4/30/26 17:16	1	0.5	0	0	1	-74.8	1.2
509469	4/30/26 17:17	0.5	0	0	0	0.5	-74.9	0.9
509470	4/30/26 17:18	0.7	0.2	0	0	0.7	-74.9	0.7
509471	4/30/26 17:19	1	0.7	0	0	1	-74.9	0.5
509472	4/30/26 17:20	1	0.6	0	0	1	-75	0.3
509473	4/30/26 17:21	0.3	0	0	0	0.3	-75	0.1

Target yang diprediksi dalam penelitian ini adalah nilai **Global Horizontal Irradiance (GHI)** satu jam ke depan.

B. Step 2 (Preprocessing Data)

Tahap preprocessing dilakukan untuk meningkatkan kualitas dataset sebelum digunakan dalam proses pelatihan model deep learning. Proses ini bertujuan untuk menghasilkan data yang lebih bersih, stabil, dan sesuai untuk

pemodelan time series. Tahap preprocessing juga berperan penting dalam meningkatkan performa model prediksi serta mengurangi pengaruh noise dan anomali pada dataset.

Dalam penelitian ini, preprocessing data meliputi beberapa tahapan utama, yaitu:

1. Data cleaning
2. Normalisation
3. Analisis Korelasi Pearson
4. Pembagian dataset

Tahapan preprocessing dilakukan secara berurutan untuk menghindari data leakage pada proses pelatihan model deep learning.

1. Data Cleaning

Data cleaning dilakukan untuk menghapus data yang tidak valid dan memastikan kualitas dataset sebelum digunakan pada proses pelatihan model. Tahap ini meliputi penanganan *missing value*, penghapusan data duplikat, serta penghapusan nilai yang tidak sesuai dengan karakteristik fisik radiasi matahari.

Nilai radiasi matahari yang bernilai negatif atau berada di luar rentang pengukuran sensor dianggap tidak valid dan dihapus dari dataset. Selain itu, data yang mengalami gangguan pengukuran akibat kesalahan sensor atau komunikasi sistem juga tidak digunakan dalam penelitian.

Tahap data cleaning bertujuan untuk mengurangi *noise* pada dataset sehingga model dapat mempelajari pola temporal radiasi matahari secara lebih optimal.

2. Normalisasi Data

Normalisasi data dilakukan untuk menyamakan skala nilai seluruh variabel input sehingga proses pelatihan model deep learning menjadi lebih stabil dan konvergen lebih cepat. Dalam penelitian ini digunakan metode Min-Max Normalization.

Persamaan Min-Max Normalization dinyatakan sebagai berikut:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (3.2.3.1)$$

Keterangan:

- X_{norm} : nilai hasil normalisasi
- X : nilai asli data
- X_{min} : nilai minimum dataset
- X_{max} : nilai maksimum dataset

Untuk menghindari data leakage, parameter normalisasi hanya dihitung menggunakan data training. Selanjutnya, parameter tersebut digunakan untuk mentransformasi data validation dan testing.

3. Analisis Korelasi Pearson

Analisis korelasi Pearson digunakan untuk mengukur kekuatan dan arah hubungan linier antara setiap variabel input dengan variabel target, yaitu Global Horizontal Irradiance (GHI). Pada tahap ini, koefisien korelasi Pearson dihitung untuk seluruh variabel yang digunakan dalam penelitian, meliputi DNI, DHI, Reflective Radiation, Net Radiation, Azimuth, dan Elevation. Nilai koefisien korelasi Pearson dihitung menggunakan Persamaan berikut:

$$\left[r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \right] \quad (3.2.3.2)$$

dengan:

- (r) = koefisien korelasi Pearson,
- (x_i) = nilai variabel input ke-(i),
- (y_i) = nilai variabel target (GHI) ke-(i),
- $(\bar{x})$ = rata-rata variabel input,
- $(\bar{y})$ = rata-rata variabel target,
- (n) = jumlah sampel data.

Nilai koefisien korelasi berada pada rentang -1 hingga 1. Nilai yang mendekati 1 menunjukkan hubungan positif yang sangat kuat, nilai yang mendekati -1 menunjukkan hubungan negatif yang sangat kuat, sedangkan nilai yang mendekati 0 menunjukkan hubungan yang lemah atau tidak terdapat hubungan linier yang signifikan. Semakin besar nilai absolut koefisien korelasi, semakin kuat hubungan antara variabel input dengan GHI.

Hasil analisis korelasi kemudian digunakan untuk menentukan peringkat variabel berdasarkan tingkat keterkaitannya terhadap GHI. Selanjutnya, peringkat tersebut menjadi dasar dalam pembentukan skenario pemodelan Multivariate LSTM, yaitu penggunaan seluruh variabel input, lima variabel dengan korelasi tertinggi, dan tiga variabel dengan korelasi tertinggi terhadap GHI. Dengan demikian, analisis korelasi Pearson berperan dalam proses seleksi fitur untuk mengidentifikasi variabel yang paling relevan serta mengevaluasi pengaruh jumlah fitur terhadap kinerja model prediksi GHI.

4. Pembentukan Dataset Time Series

Setelah proses feature engineering, data diubah ke dalam bentuk dataset time series menggunakan metode sliding window. Metode ini digunakan untuk membentuk data historis sebagai input model deep learning.

Pada penelitian ini, model menggunakan sejumlah data historis sebelumnya untuk memprediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan.

Secara matematis, pembentukan data time series dapat dinyatakan sebagai berikut:

$$X_t = [x_{t-w+1}, x_{t-w+2}, \dots, x_t] \quad (3.2.3.3)$$

$$Y_t = x_{t+h} \quad (3.2.3.4)$$

Keterangan:

- X_t : data input historis

- Y_t : target prediksi
- w : window size
- h : horizon prediksi

Pembagian Dataset

Dataset yang telah dibentuk menggunakan metode *sliding window* selanjutnya dibagi menjadi data *training* dan *testing*. Pembagian dataset dilakukan berdasarkan urutan waktu (*time series split*) untuk mempertahankan dependensi temporal data dan menghindari kebocoran informasi (*data leakage*) antar dataset.

Data *training* sebesar 80% digunakan untuk melatih model Long Short-Term Memory (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM), sedangkan data *testing* sebesar 20% digunakan untuk mengevaluasi performa model pada data yang belum pernah digunakan selama proses pelatihan. Pendekatan ini dipilih untuk memastikan kemampuan generalisasi model dalam melakukan prediksi nilai Global Horizontal Irradiance (GHI).

Tabel 3.2 Pembagian Dataset

Dataset	Persentase
Training	80%
Testing	20%

C. Step 3 (Time Series Construction)

Sliding Window

Metode sliding window digunakan untuk membentuk dataset time series yang akan digunakan sebagai input pada model *Long Short-Term Memory* (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM). Teknik ini dilakukan dengan memanfaatkan sejumlah data historis pada periode sebelumnya untuk memprediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan.

Dalam penelitian ini digunakan *window size*, yaitu 30 menit dan 60 menit. Penggunaan dua ukuran *window* tersebut bertujuan untuk mengevaluasi pengaruh panjang data historis terhadap performa prediksi model. Data radiasi matahari memiliki karakteristik yang dinamis, nonlinier, dan dipengaruhi oleh berbagai faktor atmosfer yang berubah terhadap waktu. Oleh karena itu, pemanfaatan data historis dalam bentuk urutan waktu (*sequential data*) menjadi pendekatan yang umum digunakan pada prediksi radiasi matahari berbasis *deep learning* (Neshat et al., 2023; Sorkun et al., 2020).

Window size 30 menit digunakan untuk menangkap pola perubahan radiasi matahari jangka pendek yang dipengaruhi oleh dinamika atmosfer seperti pergerakan awan dan perubahan intensitas penyinaran matahari. Sementara itu, window size 60 menit digunakan untuk memberikan informasi historis yang lebih panjang sehingga model dapat mempelajari pola temporal yang lebih stabil dan tren perubahan radiasi matahari dalam jangka waktu yang lebih luas (Alharbi & Csala, 2021; Zuo et al., 2022)

Pada model M-LSTM, proses sliding window tidak hanya menggunakan data historis GHI, tetapi juga memanfaatkan beberapa variabel input lain seperti Direct Normal Irradiance (DNI), Diffuse Horizontal Irradiance (DHI), Azimuth matahari, Elevation, serta fitur temporal berupa hour dan day of year. Penggunaan data multivariat memungkinkan model mempelajari hubungan temporal sekaligus hubungan antarvariabel yang mempengaruhi perubahan nilai GHI sehingga berpotensi meningkatkan akurasi prediksi (Tsai & Lo, 2025).

Representasi Sliding Window pada Model LSTM (Univariat)

Untuk model LSTM, input hanya terdiri atas data historis GHI.

Window Size 30 Menit

$$x_t = g[GHI_{t-1}, GHI_{t-2}, \dots, GHI_{t-n}] \quad (3.2.3.5)$$

Di mana:

x_t = Nilai variabel atau target prediksi pada waktu ke-24

g = Fungsi pemodelan atau algoritma prediksi yang digunakan

GHI_{t-1} = Nilai Global Horizontal Irradiation pada 1 langkah sebelum waktu target
(langkah ke-t-1)

GHI_{t-2} = Nilai Global Horizontal Irradiation pada 2 langkah sebelum waktu target
(langkah ke-t-2)

GHI_{t-n} = Nilai Global Horizontal Irradiation pada titik awal jendela data (historical
baseline / langkah ke-t-n)

Representasi Sliding Window pada Model M-LSTM (Multivariat)

Pada model M-LSTM, setiap *time step* terdiri atas beberapa fitur yang digunakan secara simultan.

$$x_t = [GHI_t, DNI_t, DHI_t, \text{Reflective}_t, \text{NetRad}_t, \text{Azimuth}_t, \text{Elevation}_t, \text{Hour}_t, \text{DOY}_t]$$

Untuk *window size* sebesar w , data input dibentuk menjadi:

$$\mathbf{x}_{t-n} = [GHI_{t-n}, DNI_{t-n}, DHI_{t-n}, REF_{t-n}, NET_{t-n}, AZI_{t-n}, ELEV_{t-n}, HR_{t-n}, DY_{t-n}] \quad (3.2.3.6)$$

Di mana:

$\mathbf{X}_t$ = Matriks input multivariate LSTM sepanjang jendela t menit pada waktu t

$\mathbf{x}_{t-n}$ = Vektor fitur multivariate pada langkah waktu ke-(t-n)

GHI_{t-n} = Nilai Global Horizontal Irradiation pada waktu ke-(t-n) DNI_{t-n} = Nilai Direct Normal Irradiation pada waktu ke-(t-n)

DHI_{t-n} = Nilai Diffuse Horizontal Irradiation pada waktu ke-(t-n)

REF_{t-n} = Nilai radiasi reflektif (Reflective Radiation) pada waktu ke-(t-n)

NET_{t-n} = Nilai radiasi neto (Net Radiation) pada waktu ke-(t-n)

AZI_{t-n} = Nilai sudut azimut matahari (Solar Azimuth Angle) pada waktu ke-(t-n)

$ELEV_{t-n}$ = Nilai sudut Elevation (Solar Elevation Angle) pada waktu ke-(t-n)

HR_{t-n} = Nilai komponen jam (Hour) pada waktu ke-(t-n)

DY_{t-n} = Nilai komponen hari (Day) pada waktu ke-(t-n)

Target Prediksi

Target prediksi pada penelitian ini adalah nilai Global Horizontal Irradiance (GHI) satu jam ke depan yang dinyatakan sebagai:


$$\hat{y}_t = \hat{GHI}_{t+1} \quad (3.2.3.7)$$

dengan:

- y_t = target prediksi
- w = panjang *window size*
- $t + 60$ = horizon prediksi satu jam ke depan (60 menit)

Window size merupakan parameter penting dalam pemodelan time series karena menentukan jumlah data historis yang digunakan sebagai masukan model untuk menghasilkan prediksi. Dalam penelitian ini digunakan *window size* sebesar 30 timestep. yang mengacu pada penelitian (Sorkun et al., 2020). Pemilihan nilai tersebut didasarkan pada kemampuannya dalam merepresentasikan pola temporal radiasi matahari sehingga diharapkan dapat meningkatkan kemampuan model LSTM dalam mempelajari hubungan antar waktu dan menghasilkan prediksi Global Horizontal Irradiance (GHI) yang optimal.

Ilustrasi proses pembentukan data menggunakan metode *sliding window* dengan *window size* 30 menit. ditunjukkan pada gambar 3.3



Gambar 3.3 Sliding Window 30

D. Step 4 (Model Development)

Penelitian ini menggunakan dua Deep learning untuk memprediksi nilai Global Horizontal Irradiance satu jam ke depan, yaitu:

- Long Short-Term Memory (LSTM)
- Multivariate Long Short-Term Memory (M-LSTM)

1. Long Short-Term Memory (LSTM)

Metode Long Short-Term Memory (LSTM) digunakan sebagai model dasar (*baseline*) dalam penelitian ini untuk mengevaluasi peningkatan performa yang dihasilkan oleh model Multivariate LSTM (M-LSTM). LSTM merupakan salah satu jenis jaringan saraf tiruan yang termasuk dalam keluarga Recurrent Neural Network (RNN) dan dirancang untuk mengolah data berurutan (*sequence data*) atau data deret waktu (*time series*). Keunggulan utama LSTM dibandingkan RNN konvensional adalah kemampuannya dalam menyimpan informasi jangka panjang melalui mekanisme memori internal yang terdiri dari *input gate*, *forget gate*, dan *output gate*. Dengan kemampuan tersebut, LSTM mampu mempelajari pola temporal pada data historis secara lebih efektif.


Pada penelitian ini, model Univariate LSTM menggunakan satu variabel input, yaitu data historis Global Horizontal Irradiance (GHI). Data dibentuk menggunakan *window size* sebesar 30 timestep, sehingga model memanfaatkan 30 data historis sebelumnya untuk memprediksi nilai GHI pada periode berikutnya. Pemilihan *Arsitektur ini* mengacu pada penelitian Tsai dan Lo (2025) yang menunjukkan kinerja yang baik dalam prediksi radiasi matahari serta mampu merepresentasikan pola temporal data secara efektif.

Arsitektur model yang digunakan menerapkan pendekatan *stacked LSTM* yang terdiri atas dua lapisan LSTM yang disusun secara bertingkat. Lapisan LSTM pertama terdiri dari 64 unit neuron dengan parameter *return_sequences=True* agar informasi temporal dapat diteruskan ke lapisan berikutnya. Untuk mengurangi risiko *overfitting*, setelah setiap lapisan LSTM ditambahkan *Dropout Layer* dengan nilai *dropout rate* sebesar 0,2. Selanjutnya, keluaran dari lapisan LSTM kedua

diteruskan ke *Dense Layer* yang terdiri atas satu neuron untuk menghasilkan nilai prediksi GHI (Tsai & Lo, 2025).

Dalam proses pelatihan model, digunakan **batch size sebesar 128** dan **epoch sebanyak 100**. Optimasi model dilakukan menggunakan **optimizer Adam** karena memiliki kemampuan konvergensi yang baik pada permasalahan prediksi time series. Kinerja model kemudian dievaluasi menggunakan metrik Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan koefisien determinasi (R^2).

Penjelasan arsitektur Stacked LSTM Univariate dijelaskan pada Gambar 3.4



Gambar 3.4 Arsitektur LSTM

Secara keseluruhan, arsitektur model LSTM yang digunakan dalam penelitian ini terdiri atas:

1. Input Sequence

- Data historis GHI
- Window Size: 30 timestep

2. LSTM Layer 1

- Jumlah unit: 64
- Parameter: `return_sequences=True`

3. Dropout Layer 1

- Dropout rate: 0,2

4. LSTM Layer 2

- Jumlah unit: 64

5. Dropout Layer 2

- *Dropout rate*: 0,2

6. Dense Layer

- Jumlah neuron: 1

7. Output Layer

- Prediksi nilai Global Horizontal Irradiance (GHI)

Adapun konfigurasi pelatihan model yang digunakan adalah sebagai berikut:

- **Window Size** : 30
- **Epoch** : 100
- **Batch Size** : 128
- **Optimizer** : Adam
- **Dropout Rate** : 0,2
- **Output** : Prediksi GHI

2. Multivariate Long Short-Term Memory (M-LSTM)

Multivariate Long Short-Term Memory (M-LSTM) merupakan pengembangan dari model Long Short-Term Memory (LSTM) yang memanfaatkan lebih dari satu variabel input secara simultan dalam proses pembelajaran. Berbeda dengan model Univariate LSTM yang hanya menggunakan data historis Global Horizontal Irradiance (GHI), model M-LSTM memanfaatkan beberapa variabel yang memiliki hubungan terhadap perubahan nilai GHI, yaitu Direct Normal Irradiance (DNI), Diffuse Horizontal Irradiance (DHI), Reflection Radiation, Net Radiation, Solar Azimuth Angle, Solar Elevation Angle, serta fitur temporal berupa *hour* dan *day of year*.

Penggunaan beberapa variabel input memungkinkan model untuk mempelajari tidak hanya pola temporal dari data historis GHI, tetapi juga

hubungan antarvariabel yang memengaruhi pembentukan radiasi matahari. Dengan demikian, model diharapkan mampu menghasilkan prediksi yang lebih akurat dibandingkan pendekatan univariat.

Keunggulan model M-LSTM antara lain:

- Mampu menangkap hubungan temporal dan hubungan antarvariabel secara simultan.
- Lebih representatif dalam memodelkan karakteristik data radiasi matahari yang kompleks dan nonlinier.
- Memanfaatkan informasi tambahan dari variabel radiasi, geometri matahari, dan fitur temporal untuk meningkatkan akurasi prediksi.
- Memiliki kemampuan yang lebih baik dalam menangkap dinamika perubahan radiasi matahari dibandingkan model univariat.

Pada penelitian ini, data dibentuk menggunakan *window size* sebesar 30 timestep sehingga model memanfaatkan 30 data historis sebelumnya untuk memprediksi nilai GHI pada periode berikutnya. Arsitektur model mengadopsi pendekatan *stacked LSTM* yang mengacu pada penelitian Tsai dan Lo (2025), yang menggunakan dua lapisan LSTM dengan konfigurasi 64 unit neuron pada setiap lapisan, *dropout rate* sebesar 0,2, *batch size* 128, dan *epoch* sebanyak 100 untuk prediksi radiasi matahari.

Secara keseluruhan, arsitektur model M-LSTM yang digunakan terdiri atas:

1. **Input Sequence**

- GHI
- DNI
- DHI
- Reflection Radiation
- Net Radiation
- Azimuth
- Elevation

2. **LSTM Layer 1**


- Jumlah unit: 64

- Parameter: *return_sequences=True*
- 3. **Dropout Layer 1**
 - *Dropout rate: 0,2*
- 4. **LSTM Layer 2**
 - Jumlah unit: 64
- 5. **Dropout Layer 2**
 - *Dropout rate: 0,2*
- 6. **Dense Layer**
 - Jumlah neuron: 1
- 7. **Output Layer**
 - Prediksi nilai Global Horizontal Irradiance (GHI)

Adapun konfigurasi pelatihan model yang digunakan adalah sebagai berikut:

- **Window Size** : 30
- **Epoch** : 100
- **Batch Size** : 128
- **Optimizer** : Adam
- **Dropout Rate** : 0,2
- **Output** : Prediksi GHI

Perbedaan utama antara model Univariate LSTM dan Multivariate LSTM pada penelitian ini terletak pada jumlah variabel input yang digunakan, sedangkan arsitektur jaringan dan parameter pelatihan dibuat sama untuk memastikan perbandingan performa dilakukan secara objektif. Pendekatan multivariat memungkinkan model memanfaatkan informasi dari berbagai variabel yang saling berkaitan sehingga mampu menghasilkan prediksi yang lebih akurat dibandingkan model univariat (Tsai & Lo, 2025).



Gambar 3.5 Arsitektur M-LSTM

E. Step 5 (Prediksi)

Tahap prediksi dilakukan setelah proses pelatihan model Long Short-Term Memory (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM) selesai dilaksanakan. Pada tahap ini, model yang telah dilatih digunakan untuk memprediksi nilai Global Horizontal Irradiance (GHI) satu jam ke depan berdasarkan data historis yang telah dibentuk menggunakan metode *sliding window*. Model LSTM menggunakan data historis GHI sebagai input tunggal, sedangkan model M-LSTM memanfaatkan beberapa variabel input secara simultan, yaitu GHI, DNI, DHI, Azimuth, elevasi, *hour*, dan *day of year*. Hasil prediksi yang diperoleh kemudian dikembalikan ke skala aslinya melalui proses *denormalization* sehingga dapat dibandingkan secara langsung dengan nilai aktual GHI. Tahap ini menghasilkan keluaran berupa deret waktu prediksi radiasi matahari yang selanjutnya digunakan dalam proses evaluasi dan analisis performa model.

F. Step 6 (Evaluasi Metode)

Performa model prediksi pada penelitian ini dievaluasi menggunakan tiga metrik evaluasi, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Coefficient of Determination (R^2). Ketiga metrik tersebut dipilih karena banyak digunakan dalam penelitian prediksi radiasi matahari dan mampu memberikan informasi yang komprehensif mengenai tingkat akurasi model (Voyant et al., 2017).

1. Root Mean Square Error (RMSE)

Root Mean Square Error (RMSE) digunakan untuk mengukur besarnya kesalahan prediksi dengan memberikan penalti yang lebih besar terhadap error yang tinggi. Semakin kecil nilai RMSE, semakin baik performa model dalam melakukan prediksi.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.2.3.8)$$

Keterangan:

n = jumlah data pengujian

y_i = nilai aktual

$\hat{y}_i$ = nilai prediksi

2. Mean Absolute Error (MAE)

Mean Absolute Error (MAE) digunakan untuk mengukur rata-rata kesalahan absolut antara nilai aktual dan nilai prediksi. Nilai MAE yang lebih kecil menunjukkan bahwa hasil prediksi semakin mendekati nilai aktual.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.2.3.9)$$

Keterangan:

- n = jumlah data pengujian
- y_i = nilai aktual
- $\hat{y}_i$ = nilai prediksi

3. Coefficient of Determination (R^2)

Coefficient of Determination (R^2) digunakan untuk mengukur kemampuan model dalam menjelaskan variasi data aktual. Nilai R^2 berada

pada rentang 0 hingga 1. Semakin mendekati nilai 1, semakin baik kemampuan model dalam merepresentasikan data aktual.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.2.3.10)$$

Keterangan:

y_i = nilai aktual

$\hat{y}_i$ = nilai prediksi

$\bar{y}$ = rata-rata nilai aktual

n = jumlah data pengujian


Berdasarkan ketiga metrik tersebut, model dengan nilai RMSE dan MAE yang lebih kecil serta nilai R^2 yang lebih mendekati 1 dianggap memiliki performa prediksi yang lebih baik.

G. Step 7 (Comparative analysis)

1. Analisis Musim Kemarau dan Musim Hujan.

Analisis musim dilakukan untuk mengkaji pengaruh variasi kondisi atmosfer terhadap karakteristik radiasi matahari serta performa model prediksi yang digunakan dalam penelitian. Wilayah Indonesia, termasuk Jawa Timur, memiliki dua musim utama, yaitu musim hujan dan musim kemarau. Perbedaan karakteristik atmosfer pada kedua musim tersebut dapat memengaruhi intensitas radiasi matahari yang diterima permukaan bumi dan berpotensi memengaruhi tingkat akurasi model prediksi.

Dalam penelitian ini, dataset dikelompokkan menjadi dua periode berdasarkan musim sebagaimana ditunjukkan pada Gambar 3.2.



Gambar 3. 2 Pembagian Dataset Berdasarkan Musim

Dataset yang telah melalui proses preprocessing dan pembentukan *sliding window* selanjutnya dipisahkan berdasarkan periode musim untuk dianalisis secara terpisah.

2. Karakteristik Radiasi Matahari

Analisis karakteristik radiasi matahari dilakukan untuk mengidentifikasi pola perubahan nilai Global Horizontal Irradiance (GHI) pada masing-masing musim. Analisis ini bertujuan untuk mengetahui perbedaan distribusi dan intensitas radiasi matahari antara musim hujan dan musim kemarau.

Pada musim hujan, intensitas radiasi matahari yang diterima permukaan bumi umumnya lebih rendah dan lebih fluktuatif akibat tingginya tutupan awan serta kondisi atmosfer yang lebih dinamis. Sebaliknya, pada musim kemarau kondisi atmosfer cenderung lebih stabil dengan tingkat tutupan awan yang lebih rendah sehingga intensitas radiasi matahari yang diterima permukaan bumi relatif lebih tinggi.

Untuk memahami karakteristik tersebut, dilakukan analisis melalui visualisasi data menggunakan grafik *time series* serta analisis statistik deskriptif. Statistik deskriptif yang digunakan meliputi nilai rata-rata (*mean*), nilai maksimum (*maximum*), nilai minimum (*minimum*), dan

standar deviasi (*standard deviation*) dari data GHI pada masing-masing musim. Hasil analisis ini digunakan untuk memberikan gambaran mengenai perbedaan pola radiasi matahari pada kedua musim.

3. Performa Metode Berdasarkan Musim.

Selain menganalisis karakteristik radiasi matahari, penelitian ini juga mengevaluasi performa model prediksi pada musim hujan dan musim kemarau. Analisis dilakukan untuk mengetahui kemampuan model dalam memprediksi nilai Global Horizontal Irradiance (GHI) pada kondisi atmosfer yang berbeda.

Model Long Short-Term Memory (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM) diuji menggunakan dataset yang telah dipisahkan berdasarkan periode musim. Hasil prediksi yang dihasilkan oleh masing-masing model kemudian dibandingkan dengan nilai aktual GHI untuk mengukur tingkat akurasi prediksi.

Evaluasi performa model dilakukan menggunakan tiga metrik, yaitu:

- Root Mean Square Error (RMSE)
- Mean Absolute Error (MAE)
- Coefficient of Determination (R^2)

Nilai RMSE dan MAE digunakan untuk mengukur tingkat kesalahan prediksi, sedangkan nilai R^2 digunakan untuk mengukur kemampuan model dalam menjelaskan variasi data aktual. Model dengan nilai RMSE dan MAE yang lebih rendah serta nilai R^2 yang lebih mendekati 1 dianggap memiliki performa yang lebih baik.

Hasil evaluasi pada masing-masing musim selanjutnya dibandingkan untuk mengetahui pengaruh kondisi atmosfer terhadap performa model prediksi. Analisis ini juga digunakan untuk menentukan model yang memiliki kemampuan generalisasi terbaik dalam memprediksi radiasi matahari pada kondisi musim yang berbeda.

H. Step 8 (*Result and Interpretation*)

Tahap interpretasi hasil dilakukan untuk menganalisis dan memahami performa model yang diperoleh dari proses eksperimen. Analisis dilakukan dengan membandingkan hasil prediksi model terhadap data aktual berdasarkan metrik evaluasi yang digunakan, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), dan Coefficient of Determination (R^2). Selain membandingkan performa antara model LSTM dan M-LSTM, penelitian ini juga menganalisis pengaruh kondisi musim terhadap akurasi prediksi. Hasil evaluasi selanjutnya diinterpretasikan untuk mengidentifikasi kelebihan dan keterbatasan masing-masing model dalam memprediksi Global Horizontal Irradiance (GHI) pada wilayah tropis. Tahap ini menjadi dasar dalam penyusunan pembahasan, penarikan kesimpulan, serta penyusunan rekomendasi untuk penelitian selanjutnya.

3.2.4 Alur Penelitian

Tahapan penelitian secara keseluruhan dirangkum dalam bentuk alur penelitian yang menggambarkan proses mulai dari pengumpulan data hingga evaluasi hasil prediksi. Alur penelitian disusun secara sistematis untuk memastikan setiap tahapan pengolahan data, pemilihan variabel, dan pengembangan model dilakukan secara terstruktur.

Penelitian diawali dengan proses pengumpulan dataset radiasi matahari yang diperoleh dari Automatic Solar Radiation System (ASRS) di Stasiun Klimatologi Jawa Timur. Dataset yang digunakan terdiri atas Global Horizontal Irradiance (GHI), Direct Normal Irradiance (DNI), Diffuse Horizontal Irradiance (DHI), Reflection Radiation, Net Radiation, Azimuth, Elevation, serta informasi waktu pengamatan (*timestamp*) dengan resolusi satu menit.

Tahap berikutnya adalah *preprocessing* data yang meliputi proses *data cleaning*, penanganan *missing value*, dan normalisasi data menggunakan metode Min-Max Scaling. Selain itu, dilakukan proses *feature engineering* dengan mengekstraksi fitur temporal berupa *hour* dan *day of year* untuk membantu model dalam mempelajari pola perubahan radiasi matahari berdasarkan waktu.

Setelah proses *preprocessing*, dilakukan analisis korelasi Pearson untuk mengetahui tingkat hubungan antara masing-masing variabel input terhadap variabel target GHI. Hasil analisis korelasi digunakan sebagai dasar dalam penyusunan skenario eksperimen dan pemilihan variabel yang digunakan pada model Multivariate LSTM.


Data yang telah diproses kemudian diubah ke dalam bentuk dataset *time series* menggunakan metode *sliding window* dengan ukuran jendela (*window size*) sebesar 30 timestep. Teknik ini digunakan untuk membentuk urutan data historis sebagai input model dalam memprediksi nilai Global Horizontal Irradiance (GHI) pada periode berikutnya.

Selanjutnya, dataset dibagi menjadi data *training* sebesar 80% dan data *testing* sebesar 20% menggunakan pendekatan *time series split* untuk mempertahankan urutan temporal data dan menghindari terjadinya *data leakage*.

Pada tahap pemodelan, digunakan satu model Univariate LSTM dan tiga skenario Multivariate LSTM (M-LSTM). Model Univariate LSTM menggunakan data historis GHI sebagai input, sedangkan model M-LSTM menggunakan kombinasi variabel yang berbeda berdasarkan hasil peringkat korelasi terhadap GHI. Seluruh model dilatih menggunakan konfigurasi parameter yang sama yang mengacu pada penelitian Tsai dan Lo (2025), sehingga perbandingan performa dapat dilakukan secara objektif (*fair comparison*).

Setelah proses pelatihan selesai, model digunakan untuk memprediksi nilai GHI. Hasil prediksi kemudian dikembalikan ke skala aslinya melalui proses *denormalisasi* dan dievaluasi menggunakan metrik Mean Absolute Error (MAE), Root Mean Square Error (RMSE), dan Coefficient of Determination (R^2). Tahap akhir penelitian adalah analisis hasil prediksi untuk membandingkan performa model Univariate LSTM dan Multivariate LSTM pada setiap skenario eksperimen serta menentukan kombinasi variabel yang menghasilkan performa prediksi terbaik.

Alur penelitian yang menggambarkan tahapan penelitian mulai dari proses pengumpulan data hingga evaluasi model ditunjukkan pada Gambar 3.6.



Gambar 3.6 Alur Penelitian .

3.3 Skenario Eksperimen

3.3.1 Konfigurasi dan Skenario Eksperimen

Penelitian ini bertujuan untuk membandingkan performa model Long Short-Term Memory (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM) dalam memprediksi nilai Global Horizontal Irradiance (GHI). Arsitektur model

yang digunakan mengacu pada penelitian Tsai dan Lo (2025) dengan konfigurasi *stacked LSTM* yang terdiri dari dua lapisan LSTM, *dropout rate* sebesar 0,2, *batch size* 128, dan *epoch* sebanyak 100.

Untuk memperoleh perbandingan yang objektif (*fair comparison*), seluruh model menggunakan arsitektur dan parameter pelatihan yang sama. Perbedaan antar model hanya terletak pada jumlah dan jenis variabel input yang digunakan pada setiap skenario eksperimen.

Konfigurasi parameter yang digunakan dalam proses pelatihan model ditunjukkan pada Tabel 3.2.

Tabel 3.2 Konfigurasi Eksperimen

Parameter	Nilai
Window Size	30
Batch Size	128
Epoch	100
Optimizer	Adam
Learning Rate	0,001
Loss Function	Mean Squared Error (MSE)
LSTM Layer 1	64 Unit
LSTM Layer 2	64 Unit
Dropout Rate	0,2
Data Split	80% : 20%

Sebelum proses pemodelan dilakukan, analisis korelasi Pearson digunakan untuk mengetahui tingkat hubungan antara masing-masing variabel input terhadap variabel target GHI. Hasil analisis korelasi kemudian digunakan sebagai dasar dalam penyusunan skenario eksperimen dengan memilih variabel berdasarkan peringkat korelasinya terhadap GHI.

Berdasarkan pendekatan tersebut, penelitian ini menggunakan tiga skenario eksperimen pada model Multivariate LSTM untuk mengevaluasi pengaruh jumlah variabel input terhadap performa prediksi GHI. Skenario eksperimen yang digunakan ditunjukkan pada Tabel 3.3.

Tabel 3.3 Skenario Eksperimen

No	Model	Variabel Input
1	LSTM (Univariate)	GHI
2	M-LSTM Skenario 1	Seluruh variabel input
3	M-LSTM Skenario 2	Lima variabel dengan peringkat korelasi tertinggi terhadap GHI
4	M-LSTM Skenario 3	Tiga variabel dengan peringkat korelasi tertinggi terhadap GHI

Performa setiap model dievaluasi menggunakan metrik Mean Absolute Error (MAE), Root Mean Square Error (RMSE), dan Coefficient of Determination (R^2). Hasil evaluasi digunakan untuk menganalisis pengaruh jumlah variabel input terhadap performa prediksi serta menentukan kombinasi variabel yang menghasilkan akurasi prediksi GHI terbaik.

3.3.2 Implementasi Model

Model deep learning dalam penelitian ini diimplementasikan menggunakan bahasa pemrograman Python yang dijalankan melalui platform Google Colaboratory (Google Colab). Platform tersebut dipilih karena menyediakan lingkungan komputasi berbasis *cloud* yang mendukung proses pengolahan data, pelatihan model, serta evaluasi model deep learning secara efisien tanpa memerlukan perangkat keras dengan spesifikasi tinggi.

Proses implementasi meliputi tahapan *preprocessing* data, pembentukan *sequence* menggunakan metode *sliding window*, pelatihan model Long Short-Term Memory (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM), serta evaluasi hasil prediksi menggunakan metrik MAE, RMSE, dan R^2 . Library yang digunakan dalam penelitian ini ditunjukkan pada Tabel 3.4.

Tabel 3.4 Tabel Library Yang Digunakan

Library	Fungsi
NumPy	Operasi numerik dan manipulasi array
Pandas	Pengolahan dan analisis dataset
Scikit-learn	Preprocessing dan evaluasi model
TensorFlow / Keras	Implementasi dan pelatihan model LSTM dan M-LSTM
Matplotlib	Visualisasi data dan hasil prediksi

Implementasi model dilakukan menggunakan arsitektur *stacked LSTM* yang mengacu pada penelitian Tsai dan Lo (2025). Seluruh proses pelatihan dan pengujian model dilakukan menggunakan konfigurasi parameter yang sama sehingga perbandingan performa antar skenario eksperimen dapat dilakukan secara objektif.

3.3.3 Lingkungan Pengujian

Penelitian ini diimplementasikan menggunakan platform Google Colaboratory (Google Colab) yang menyediakan lingkungan komputasi berbasis *cloud* untuk mendukung proses pengolahan data, pelatihan model, dan evaluasi hasil prediksi. Penggunaan Google Colab memungkinkan proses eksperimen dilakukan secara efisien dengan dukungan sumber daya komputasi yang memadai untuk menjalankan model Long Short-Term Memory (LSTM) dan Multivariate Long Short-Term Memory (M-LSTM). Adapun spesifikasi lingkungan pengujian yang digunakan dalam penelitian ini ditunjukkan pada Tabel 3.5.

Tabel 3.5 Spesifikasi Lingkungan Pengujian seperti berikut:


Komponen	Spesifikasi
Platform	Google Colaboratory (Google Colab)
Bahasa Pemrograman	Python 3.
Sistem Operasi	Linux (Cloud Environment)
Runtime	GPU Google Colab
Jenis Pengolahan	Deep Learning Time Series
Metode	LSTM dan Multivariate LSTM

3.4 Plemenary study


3.4.1 Karakteristik Data

Tabel 3.6 Karateristik Data

Parameter ASRS	Jumlah Sampel	Rata-rata (Mean)	Standar Deviasi	Nilai Minimum	Kuartil 25%	Median (50%)	Kuartil 75%	Nilai Maksimum
GHI	543066	191.61	296.09	0	0	3.352	308.8	1492
Diffuse	543066	98.62	145.67	0	0	3.4	162.2	833
DNI	543066	115.80	228.77	0	0	0	47.45	1016
Reflective Rad.	543066	43.51	66.64	0	0.285	2.4	69.8	338.9
Nett. Rad.	543066	148.10	229.71	-6.553	0	1.7	239.1	1153
Azzimuth	543066	60.30	79.06	0	0	28.3	90.8	269.01
Altitude	543066	13.64	32.31	-15	-15	0.612	42.3	89.919



Gambar 3.7 Grafik Boxplot Komparatif



Gambar 3.8 Matriks Korelasi Antar Variabel

Tabel 3.7 Tabel Peringkat Korelasi

TABEL PERINGKAT KORELASI TERHADAP GHI		
Variabel	Nilai Korelasi Pearson (r)	Kategori Hubungan Fisis
GHI	1.0000	Korelasi Sempurna (Target Utama)
Nett. Rad.	0.9997	Hubungan Sangat Kuat
Reflective Rad.	0.9969	Hubungan Sangat Kuat
DNI	0.8423	Hubungan Sangat Kuat
Altitude	0.8383	Hubungan Sangat Kuat
Diffuse	0.7754	Hubungan Kuat (Kontribusi Tinggi)
Azzimuth	0.2974	Hubungan Lemah (Kontribusi Rendah)

Konfigurasi pada Model LSTM dan M-LSTM yang digunakan sebagai berikut :

Window size: 30 ,Epoch:100, Batch size: 128, LSTM 1 (64 unit), Dropout (0.2), LSTM 2 (64 unit), Dense (32), Output (1 neuron), Optimizer: Adam, Loss function: Mean Squared Error (MSE), Split data: 80% training dan 20% testing (Tsai & Lo, 2025)


3.4.2 Analisis Eksperimen

3.4.2.1 Analisis Musim Hujan


Pengujian sensitivitas fitur pada musim hujan dilakukan untuk mengevaluasi pengaruh jumlah variabel input terhadap performa model Multivariate Long Short-Term Memory (M-LSTM). Tiga skenario diuji, yaitu penggunaan 7 fitur lengkap, 5 fitur dengan korelasi tertinggi terhadap GHI, dan 3 fitur dengan korelasi tertinggi terhadap GHI. Hasil pengujian kemudian dibandingkan dengan model LSTM univariat yang hanya menggunakan data historis GHI sebagai input.

A. Skenario 1 (7 Fitur Lengkap)

Pada Skenario 1 yang menggunakan 7 fitur lengkap, model menghasilkan nilai R^2 sebesar 76,61%, MAE sebesar 71,75 W/m², dan RMSE sebesar 151,85 W/m². Meskipun menggunakan seluruh variabel yang tersedia dari sistem ASRS, performa model masih berada di bawah Skenario 2. Hal ini mengindikasikan bahwa tidak semua variabel memberikan kontribusi positif terhadap proses prediksi, sehingga keberadaan beberapa fitur dapat menambah kompleksitas model dan memengaruhi kemampuan generalisasi.



Gambar 3.9 Perbandingan Nilai Aktual dan Prediksi M-LSTM Skenario 1




Gambar 4.0 Scaterd Plot Regresi M-LSTM Musim Hujan Skenario 1


Berdasarkan Gambar 4.0, kurva hasil prediksi mampu mengikuti pola umum data aktual selama periode pengujian. Model masih dapat menangkap tren perubahan radiasi matahari meskipun terdapat beberapa perbedaan pada nilai puncak dan lembah radiasi. Hasil ini menunjukkan bahwa penggunaan seluruh variabel input mampu membantu model dalam merepresentasikan karakteristik GHI dengan nilai R² sebesar 76,61%..

B. Skenario 2 (5 Variabel dengan Korelasi Tertinggi)

Berdasarkan hasil pengujian, Skenario 2 dengan 5 fitur terkuat (GHI, Nett, Reflective, DNI, Altitude) mendominasi akurasi tertinggi sebesar 82.16% dengan tingkat eror terendah (MAE: 64.26 W/m²). Secara fisis, pembatasan fitur pada 5 variabel ini berhasil mereduksi redundansi data. Kombinasi interaksi radiasi langsung (DNI), total (GHI), keseimbangan energi (Nett, Reflective), dan sudut datang matahari (Altitude) memberikan asupan informasi yang paling efisien dan padat bagi arsitektur Stacked LSTM dalam mendeteksi perubahan cuaca dalam rentang pendek (30 menit).



Gambar 4.1 Perbandingan Nilai Aktual dan Prediksi M-LSTM Skenario 2




Gambar 4.2 Scatterd Plot Regresi M-LSTM Musim Hujan Skenario 2


Pada Skenario 2, pola prediksi masih menunjukkan kesesuaian yang tinggi terhadap data aktual. Meskipun jumlah fitur dikurangi, model tetap mampu mempertahankan performa yang baik dengan nilai R^2 sebesar 82.16%. Hal ini menunjukkan bahwa sebagian besar informasi penting telah direpresentasikan oleh lima variabel dengan korelasi tertinggi terhadap GHI.

C. Skenario 3 (3 Variabel dengan Korelasi Tertinggi)

Hasil prediksi pada Skenario 3 masih mampu mengikuti pola data aktual, namun terlihat beberapa deviasi pada periode radiasi tinggi. Pengurangan jumlah fitur menyebabkan sebagian informasi yang memengaruhi GHI tidak lagi tersedia sehingga performa model menurun dibandingkan Skenario 1 dan Skenario 2. Hal tersebut ditunjukkan oleh nilai R^2 sebesar 75,58%, MAE sebesar 82,67 W/m², dan RMSE sebesar 155,17 W/m².



Gambar 4.3 Perbandingan Nilai Aktual dan Prediksi M-LSTM Skenario 3




Gambar 4.4 Scaterd Plot Regresi M-LSTM Musim Hujan Skenario 3


Hasil prediksi pada Skenario 3 masih mampu mengikuti pola data aktual, namun terlihat beberapa deviasi pada puncak radiasi matahari. Pengurangan jumlah fitur menyebabkan sebagian informasi yang memengaruhi GHI tidak lagi tersedia sehingga performa model sedikit menurun dibandingkan Skenario 1 dan Skenario 2 dengan nilai dengan nilai R^2 sebesar 75.58%.

D. LSTM Univariate

. Model LSTM hanya menghasilkan nilai R^2 sebesar 76.73%, MAE sebesar 83.23 W/m^2 , dan RMSE sebesar 151.47 W/m^2 .



Gambar 4.5 Perbandingan Nilai Aktual dan Prediksi LSTM



Gambar 4.6 Scatter Plot Regresi LSTM Musim Hujan

Model Univariate LSTM menghasilkan pola prediksi yang mampu mengikuti tren umum data aktual, namun masih terdapat penyimpangan yang lebih besar dibandingkan model multivariat, terutama pada saat terjadi perubahan radiasi matahari yang cepat. Hasil ini menunjukkan bahwa penggunaan data historis GHI

saja belum cukup untuk merepresentasikan seluruh faktor yang memengaruhi perubahan nilai GHI.


3.4.3 Kesimpulan sementara

Berdasarkan hasil pengujian sensitivitas fitur pada musim hujan, Skenario 2 yang menggunakan lima variabel dengan korelasi tertinggi terhadap GHI menghasilkan performa terbaik dengan nilai R^2 sebesar 82,16%, MAE sebesar 64,26 W/m², dan RMSE sebesar 132,61 W/m². Hasil tersebut lebih baik dibandingkan model LSTM univariat maupun skenario lainnya.

Temuan ini menunjukkan bahwa penggunaan parameter radiasi matahari dan geometri matahari yang diperoleh dari Automatic Solar Radiation System (ASRS) mampu meningkatkan akurasi prediksi dibandingkan penggunaan data historis GHI saja. Selain itu, hasil penelitian juga menunjukkan bahwa pemilihan fitur yang tepat memiliki pengaruh penting terhadap performa model. Penggunaan lima fitur terpilih mampu menghasilkan akurasi yang lebih tinggi dibandingkan penggunaan seluruh fitur maupun hanya tiga fitur, sehingga konfigurasi tersebut dipilih sebagai model terbaik untuk prediksi GHI satu jam ke depan pada musim hujan.

Tabel 3.8 Hasil Evaluasi Pada Musim Hujan

TABEL EVALUASI SENSITIVITAS FITUR (MUSIM HUJAN)				
Skenario	R2 Score (%)	MAE	RMSE	
Skenario 1 (7 Fitur)	76.61%	71.75	151.85	
Skenario 2 (5 Fitur)	82.16%	64.26	132.61	
Skenario 3 (3 Fitur)	75.58%	82.67	155.17	
Model Univariate (1 Fitur)	76.73%	83.23	151.47	



Gambar 4.7 Grafik Kombinasi Evaluasi Musim Hujan

Hasil pengujian sensitivitas fitur menunjukkan bahwa model Multivariate LSTM dengan lima fitur menghasilkan performa terbaik dengan nilai R^2 sebesar 82,16%, MAE sebesar 64,26 W/m^2 , dan RMSE sebesar 132,61 W/m^2 . Temuan ini sejalan dengan penelitian **Tsai dan Lo (2025)** yang melaporkan bahwa model multivariat memiliki performa lebih baik dibandingkan model univariat. Pada penelitian tersebut, model Multivariate LSTM menghasilkan nilai NRMSE sebesar 0,159, sedangkan model univariat memperoleh NRMSE sebesar 0,213. Kesamaan hasil tersebut menunjukkan bahwa penggunaan beberapa variabel yang relevan mampu meningkatkan kemampuan model dalam mempelajari hubungan kompleks yang memengaruhi radiasi matahari. Selain itu, hasil penelitian ini menunjukkan bahwa penggunaan seluruh fitur tidak selalu menghasilkan performa terbaik. Model dengan lima fitur terpilih justru memberikan akurasi yang lebih tinggi dibandingkan penggunaan tujuh fitur maupun tiga fitur. Hal ini mengindikasikan bahwa proses seleksi fitur memiliki peran penting dalam meningkatkan kinerja model prediksi GHI.

DAFTAR PUSTAKA

- Alharbi, F. R., & Csala, D. (2021). Wind speed and solar irradiance prediction using a bidirectional long short-term memory model based on neural networks. *Energies*, 14(20). <https://doi.org/10.3390/en14206501>
- Alkhatib, F. Y., Alsadi, J., Ramadan, M., Nasser, R., Awdallah, A., Chrysikopoulos, C. V, & Maalouf, M. (2025). Comparative analysis of deep learning techniques for global horizontal irradiance forecasting in US cities. *Clean Energy*, 9(2), 66–83. <https://doi.org/10.1093/ce/zkae097>
- Azmi, M. S. M., Supian, F. L., & Othman, M. Y. (2023). The Sun as the Energy Source for Human Beings from the Perspectives of Qur'an and Science. *Sains Humanika*. <https://sainshumanika.utm.my/index.php/sainshumanika/article/view/2002>
- Badan Meteorologi dan Geofisika, K. (2021). *Prakiraan Musim Hujan dan Musim Kemarau di Indonesia*. BMKG. <https://www.bmkg.go.id/iklim/prakiraan-musim.bmkg>
- Bedoya, Díaz, D., Mario González Rodríguez, X. S. G., & Clairand, J. M. (2025). *Solar Irradiance Forecasting With Deep Learning and Ensemble Models: LSTM, Random Forest and Extra Trees With Multivariate Meteorological Data*. 1–18. <https://doi.org/10.1049/stg2.70019>
- Bektas, S. C., & Altas, I. H. (2024). DWT-BILSTM-based models for day-ahead hourly global horizontal solar irradiance forecasting. *Neural Computing and Applications*. <https://doi.org/10.1007/s00521-024-09701-2>
- Delgado, C. J., Estefanía Alfaro-Mejía, Manian, V., & Andrade, E. O.-C. and F. (2024). *Photovoltaic Power Generation Forecasting with Hidden Markov Model and Long Short-Term Memory in MISO and*.
- Domínguez, M., Riquelme-Santos, J. M., & Rivas-Dávalos, F. (2024). Deep

- learning approaches for solar irradiance forecasting using ERA5 dataset. *Energy Reports*, 10, 455–468. <https://doi.org/10.1016/j.egyr.2024.01.034>
- Duffie, J. A., & Beckman, W. A. (2013). *Solar Engineering of Thermal Processes*. Wiley.
- Fadillah, N. (2024). Study of the Hadith Regarding Fever in the Perspective of Ma'anil Hadith Yusuf Qardhawi. *Spiritus Journal*. <https://ejournal.imbima.org/index.php/spiritus/article/view/63>
- Fahmi, A. (2023). Analisis Sinonimitas Makna Nur, Diya, dan Siraj dalam Al-Qur'an. *Jurnal Moderasi*. <https://ejournal.uin-suka.ac.id/ushuluddin/moderasi/article/view/6962>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Huang, D., He, J., Song, Y., Guo, Z., Huang, X., & Guo, Y. (2022). Displacement Prediction of the Muyubao Landslide Based on a GPS Time-Series Analysis and Temporal Convolutional Network Model. *Remote Sensing*, 14(11). <https://doi.org/10.3390/rs14112656>
- Huang, J., Korolkiewicz, M., Agrawal, M., & Boland, J. (2020). Forecasting solar radiation using machine learning techniques. *Energy*, 201, 117657. <https://doi.org/10.1016/j.energy.2020.117657>
- Husein, A. A. M., & Syahid, A. H. (2025). Fenomena Alam dalam Perspektif Hadis dan Sains Modern. *Al-Mustaqbal Journal*. <https://ibnusinapublisher.org/index.php/AL-MUSTAQBAL/article/view/232>
- International Energy Agency. (2023). *World Energy Outlook 2023*. International Energy Agency. <https://www.iea.org/reports/world-energy-outlook-2023>
- Kaysal, K., Hocaoglu, F. O., Yurttakal, A. H., & Erbay, H. (2025). M/LSTM-GRU Hybrid Model for Solar Radiation Estimation. *Comptes Rendus de l'Académie Bulgare Des Sciences*, 78(6), 894–903.

<https://doi.org/10.7546/CRABS.2025.06.12>

- Khan, A. W., Duan, J., Nawaz, F., & Lu, W. (2025). Novel hybrid BiLSTM-BiGRU and CNN-LSTM architectures for enhanced solar irradiance forecasting in semi-arid climates. *International Journal of Electrical Power and Energy Systems*, 172. <https://doi.org/10.1016/j.ijepes.2025.111380>
- Meddahi, A., Tuomiranta, A., & Guillon, S. (2025). Skill-Driven Data Sampling and Deep Learning Framework for Minute-Scale Solar Forecasting With Sky Images. *Solar RRL*, 9(4). <https://doi.org/10.1002/solr.202400664>
- Neshat, M., Majidi, M., Mirjalili, S., & Astiaso, D. (2023). Short-term solar radiation forecasting using hybrid deep residual learning and gated LSTM recurrent network with differential covariance matrix adaptation evolution strategy. *Energy*, 278(May), 127701. <https://doi.org/10.1016/j.energy.2023.127701>
- Nugraha, M. R., & Adriansyah, A. (2022). Development of a solar radiation sensor system with pyranometer. *International Journal of Electrical Engineering*. <https://www.academia.edu/download/91882892/15482.pdf>
- Nuraini, N., & Fitri, N. I. (2022). Analisis sifat hujan dan rata-rata temperatur udara bulanan di Indonesia. *Jurnal Aplikasi Meteorologi*. <https://stmkg.balai2bmkg.id/index.php/jam/article/view/14>
- Oyelami, S., Azeez, N. A., & Adedigba, S. A. (2020). A pyranometer for solar radiation measurement: Review. *Journal of Physics*. <https://www.researchgate.net/publication/349210517>
- Rocha, A. B., Fernandes, E. M., Santos, C. A. C., & Diniz, J. M. T. (2021). Development of a real-time surface solar radiation measurement system based on the internet of things (IoT). *Sensors*, 21(11), 3836. <https://doi.org/10.3390/s21113836>
- Sorkun, M. C., Incel, O. D., & Paoli, C. (2020). Time Series Forecasting on Multivariate Solar Radiation Data Using Deep Learning (LSTM). *Turkish*

Journal of Electrical Engineering & Computer Sciences.
<https://journals.tubitak.gov.tr/elektrik/vol28/iss1/15/>

Suratno, S., & Cahyono, B. D. (2023). Rancang Bangun Sistem Pembangkit Listrik Tenaga Surya (PLTS) Sebagai Catu Daya Pompa Air Submersible. *Jurnal Teknik Elektro Uniba (Jte Uniba)*, 7(2), 309–319.
<https://doi.org/10.36277/jteuniba.v7i2.220>

Susilo, B. (2021). *Mengenal Iklim dan Cuaca di Indonesia*.
<https://books.google.com/books?id=Cl5zEAAQBAJ>

Suwadana, F. A., Garniwa, P. M. P., & Putera, D. A. (2025). Solar Irradiance Estimation in Tropical Regions Using RNN and WRF Models. *Energies*, 18(4), 925. <https://doi.org/10.3390/en18040925>

Tsai, & Lo, I.-C. (2025). Application of Long Short-Term Memory Networks and SHAP Evaluation in the Solar Radiation Forecast. *Energies*, 18, 6099.
<https://doi.org/10.3390/en18236099>

Voyant, C., Notton, G., Kalogirou, S., Nivet, M., Paoli, C., Motte, F., & Fouilloy, A. (2017). Machine learning methods for solar radiation forecasting: A review. *Renewable Energy*, 105, 569–582.
<https://doi.org/10.1016/j.renene.2016.12.095>

Yang, D., Kleissl, J., Gueymard, C., Pedro, H., & Coimbra, C. (2020). History and trends in solar irradiance and photovoltaic power forecasting. *Solar Energy*, 187, 3–16. <https://doi.org/10.1016/j.solener.2019.05.042>

Yildirim, Kose, R., & Aydin, M. (2023). Deep learning-based solar radiation prediction for photovoltaic applications. *Solar Energy*, 249, 1–12.
<https://doi.org/10.1016/j.solener.2022.11.026>

Zhang, J., Hong, L., Ibrahim, S. N., & He, Y. (2024). Short-term prediction of behind-the-meter PV power based on attention-LSTM and transfer learning. *IET Renewable Power Generation*, 18(3), 321–330.
<https://doi.org/10.1049/rpg2.12829>

Zuo, H.-M., Qiu, J., Jia, Y.-H., Wang, Q., & Li, F.-F. (2022). Ten-minute prediction of solar irradiance based on cloud detection and a long short-term memory (LSTM) model. *Energy Reports*, 8, 5146–5157. <https://doi.org/10.1016/j.egyr.2022.03.182>